# Vorlesung Algorithmen und Datenstrukturen (AD)

# 4

### Prof. Dr. Matthias Rarey

Zentrum für Bioinformatik, Universität Hamburg Bundesstraße 43, 20146 Hamburg rarey@zbh.uni-hamburg.de

www.zbh.uni-hamburg.de

# 3 ...

# Organisatorisches: Übungen

### ■ Übungen (14tg, erstmalig am 24. Okt.)

_	•	· ·	,	
<ol> <li>Mi</li> </ol>		12-14	Frank Heitmann	F-009
2. Mi		14-16	Florian Lauck	ZBH-R16
3. Mi		14-16	Mathias von Behren	F-534
<b>4</b> . Mi		14-16	Matthias Hilbig	F-635
<ol><li>Mi</li></ol>		16-18	Mathias von Behren	D-129
6. Mi		16-18	Matthias Hilbig	F-534
<b>7</b> . Do		10-12	Frank Heitmann	F-334
8. Do		10-12	Jan Henrik Röwekamp	F-534
9. Fr		10-12	Thomas Otto	ZBH-R16
10. Fr		12-14	Thomas Otto	ZBH-R16
	2. Mi 3. Mi 4. Mi 5. Mi 6. Mi 7. Do 8. Do 9. Fr	<ol> <li>Mi</li> <li>Mi</li> <li>Mi</li> <li>Mi</li> <li>Mi</li> <li>Do</li> <li>Fr</li> </ol>	2. Mi 14-16 3. Mi 14-16 4. Mi 14-16 5. Mi 16-18 6. Mi 16-18 7. Do 10-12 8. Do 10-12 9. Fr 10-12	<ol> <li>Mi 14-16 Florian Lauck</li> <li>Mi 14-16 Mathias von Behren</li> <li>Mi 14-16 Matthias Hilbig</li> <li>Mi 16-18 Mathias von Behren</li> <li>Mi 16-18 Matthias Hilbig</li> <li>Do 10-12 Frank Heitmann</li> <li>Do 10-12 Jan Henrik Röwekamp</li> <li>Fr 10-12 Thomas Otto</li> </ol>

■ In den Übungen besteht Anwesenheitspflicht [ 6 von 7 ].

# Organisatorisches: Vorlesung

#### Module:

■ BSc Informatik: Modul InfB-AD / IP04

■ BSc Computing in Science

■ MSc Bioinformatik: Modul MBI-04 (AD)

■ Wahlpflichtveranstaltung in weiteren Informatik-Studiengänge

Nebenfach Informatik

#### Vorlesung

■ Mi 10-12h c.t. Phil C 7tg,

■ Fr 14-16h c.t. Phil B 14tg, erstmalig 19.10

#### Sprechstunden

■ nach Vereinbarung (oder nach der Vorlesung)

■ Zentrum für Bioinformatik, Bundesstraße 43, Raum 205

■ Terminvereinbarung: geringhoff@zbh.uni-hamburg.de



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al, MIT Press, 2009 2

# Organisatorisches: Übungszettel, zeitlicher Ablauf

# **■** Übungsblätter

■ Ausgabe der Zettel: Mo ca. 12h, 14tg, erstmalig am 17.10 (29.10)

Online unter: www.stine.uni-hamburg.de

Oder: ZBH-Foyer

Oder: Stellingen: Treppenhaus Haus C/D, 1. Stock

■ Abgabe der Lösungen: Mo 12h [Woche +1]

< Absprache mit den Ü-Leitern>

Online: nur 1 pdf-Dokument

Oder: ZBH-Foyer, bzw.

Stellingen: Treppenhaus Haus C/D, 1. Stock

■ Besprechung/Vorrechnen: in der Übung [Woche +1]

# Organisatorisches: Studienleistung

- Bearbeitung der Ü-Blätter in Gruppen mit 2-3 Studierenden
- Fristgerechte Abgabe der Lösungen
- 50% der erreichbaren Punkte auf den Ü-Blättern
- Mindestens 1 Punkt auf 6 von 7 Ü-Blättern
- Anwesenheitspflicht bei 6 von 7 Übungen (abzgl. Krankmeld.)
- Keine Punkte für offensichtlich abgeschriebene Lösungen (für alle beteiligten Gruppen)
- Mind. eine erfolgreiche Präsentation einer Übungsaufgabe durch die Gruppe:
  - Ü-Gruppenleiter wählt unter korrekten Lösungen und anwesenden Gruppen eine Gruppe aus
  - Ü-Gruppenleiter bestimmt für Teillösungen, wer aus der Gruppe diese präsentiert.



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al, MIT Press 2009

# Organisatorisches: Literatur

T.H. Cormen, C.E. Leiserson, R.L. Rivest, C. Stein engl. Originalausgabe:

Introduction to Algorithms, MIT Press, 2009, (3. Aufl.) deutsche Übersetzung:

Algorithmen – Eine Einführung, Oldenbourg Wissenschaftsverlag, überarbeitete Auflage 2010

#### Foliensammlung:

Ausgedrucktes Skript, Updates über STINE [nur für den eigenen Gebrauch!]



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al,

6

# Themenschwerpunkte

#### **■** Themen:

- Entwurf von Algorithmen und Datenstrukturen
- Beschreibung von Algorithmen
- Analyse der Platz- und Zeitkomplexität
- Algorithmen f
  ür h
  äufig auftretende Probleme

# Kapitel

- 1. Algorithmen und deren Komplexität
- 2. Grundlegende Datenstrukturen
- 3. Sortieren
- 4. Suchen
- 5. Graphen
- 6. Dynamische Programmierung
- 7. Lösen schwerer Probleme

# Kapitel 1: Algorithmen und deren Komplexität

Beschreibung von Algorithmen Analyse von Algorithmen O-Notation Das Maxsum-Subarray-Problem

# 1.1 Beschreibung von Algorithmen

#### ■ Informatik = <u>Information</u> + Mathe<u>matik</u>

- entstand mit der Entwicklung der ersten Rechenanlagen (40'er J.)
- anglo-amerikanisch: Computer Science
- Wissenschaft vom "mechanischen Rechnen"

### ■ Algorithmus (von Al-Chowarizmi, persischer Math., ca. 780)

= mechanisch ausführbares Rechenverfahren

BSP [Algorithmus]: GGT (Euklid, 300 v.Chr.)

ggt(a,b): 1. a = b\*q + r mit r < b (ganzzahlige Division)

2. falls r=0: output b

3.  $a \leftarrow b$ ;  $b \leftarrow r$ ;

4. gehe zu Schritt 1.



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al, MIT Press, 2009

# Beschreibung von Algorithmen

- Spezifikation: Beschreibung des Problems
  - vollständig: alle Anforderungen und Rahmenbedingungen
  - detailliert: welche Hilfsmittel / Basisoperation sind erlaubt
  - unzweideutig: klare Kriterien für akzeptable Lösungen
- Bsp: Eine Lokomotive soll die auf Gleis A stehenden Wagen 1,2,3 in Reihenfolge 3,1,2 auf Gleis C abstellen.
  - Vollständigkeit:
    - Wie viele Wagen kann die Lok auf einmal ziehen?
  - Detailliertheit:
    - Welche Aktionen kann die Lok ausführen?
  - Unzweideutigkeit:
    - Darf die Lok am Ende zwischen den Wagen stehen?
- Beschreibung durch Vorbedingung / Nachbedingung



#### Begriffe

- "Problem": definiert eine Eingabe-Ausgabe-Beziehung
- "Instanz": eine mögliche Eingabe für das Problem
- "Algorithmus": definiert eine Folge elementarer Anweisungen zur Lösung eines Problems
- "Korrektheit": Ein Algorithmus stoppt für jede mögliche Eingabe mit der korrekten Ausgabe

### ■ Eigenschaften von Algorithmen:

- mechanische Verfahren
- bestehen aus mehreren elementaren Schritten
- Schritte werden ggf. wiederholt durchlaufen [Iteration]
- Schritte werden ggf. bedingt durchlaufen [Selektion]
- Das Verfahren führt sich ggf. selbst mit veränderten Parametern aus [Rekursion]



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al. MIT Press, 2009

10

# Beschreibung von Algorithmen

### Beschreibungsformen:

- 1. Natürliche Sprache
- 2. Computerprogramme
- 3. Hardwareentwurf
- Mischung aus 1. und 2. → <u>Pseudo-Code</u>

Regel: Wie die Spezifikation muss der Algorithmus vollständig, detailliert und unzweideutig beschrieben sein.

#### ■ Pseudo-Code:

- Angelehnt an imperative Programmiersprachen (Pascal, C, ...)
- Kontroll- und Datenstrukturen werden aus P-Sprachen übernommen
- Bedingungen, Funktionen werden ggf. natürlich-sprachlich formuliert

### Beschreibung von Algorithmen

- Pseudo-Code Konventionen (aus Cormen et al, ab 3. Aufl.)
  - Einrücken kennzeichnet die Blockstruktur.
  - 2. if [elseif] else Anweisungen für die bedingte Ausführung
  - 3. while, for to/downto, repeat until Anweisungen für die iterative Ausführung
    - while <Bedingung ist wahr>
    - for <variable> ← <Wert/Ausdruck> to <Wert/Ausdruck>

Anw1

Anw2 ...

repeat Anw1

Anw2 ...

until <Bedingung ist wahr>

- Achtung: Variable der for-Schleife ist auch noch nach Schleifenende definiert (C-Konvention)
- 4. // leiten Kommentare ein
- 5. == steht für den Vergleich von Ausdrücken, = für die Zuweisung



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al. MIT Press, 2009

# Beispiel: Euklids GGT-Algorithmus

#### Algorithmus zur Berechnung des GGT:

```
BSP [Algorithmus]: GGT (Euklid, 300 v.Chr.)
   ggt(a,b):
                  1. a = b*q + r mit r < b (ganzzahlige Division)
                  2. falls r=0: output b
                  3. a \leftarrow b; b \leftarrow r;
                  4. gehe zu Schritt 1.
Iterative Variante:
GGT(a, b)
                           // Annahme: a > b
   while a mod b >
        r = a \mod b
         a = b; b = r
   return b
Rekursive Variante:
GGT(a, b)
                           // Annahme: a > b
   r = a \mod b
   if r > 0 return GGT(b, r)
   else
                  return b
```

#### Pseudo-Code Konventionen

- 6. Feldelemente werden durch eckige Klammern indiziert, Teilfelder durch Indexbereiche, A[i], A[i..i]
- 7. Zusammenhängende Daten werden als Objekte mit Attributen dargestellt, das Objektattribut wird durch den .- Operator spezifiziert, A. länge bezeichnet die Anzahl der Elemente von Array A
- 8. Funktionsparameter werden als Wert übergeben (call-byvalue), Objekt- und Array-Bezeichner repräsentieren die Adresse des Objektes
- Boole'sche Operatoren werden träge ausgewertet (lazy evaluation), d.h. von links nach rechts bis der Ausdruck garantiert falsch oder wahr ist.

x und y: y wird nur ausgewertet, wenn x wahr ist. x oder y: y wird nur ausgewertet, wenn x falsch ist.




© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al, MIT Press, 2009

# 1.2 Analyse von Algorithmen

- Ziel: theoretische (d.h. ohne ein Computerprogramm zu schreiben) Analyse von Problemen und Algorithmen
  - Welche Probleme sind lösbar?
  - Welche Unterschiede gibt es in der Mächtigkeit von Computermodellen?
  - Welche Ressourcen (Zeit, Speicherplatz) werden mindestens benötigt?
  - Ist der Algorithmus für das Problem korrekt?
  - Welche Ressourcen benötigt ein gegebener Algorithmus?



MIT Press, 2009

### Korrektheit von Algorithmen

#### Formale Korrektheit

- Angabe von Vor- und Nachbedingung für jede Anweisung
- Schleifeninvariante: Bedingung, die vor, w\u00e4hrend (d.h. nach jeder Iteration) und nach Ausf\u00fchrung einer Schleife g\u00fcltig ist
- Bsp: Berechnung von a<sup>k</sup> für k > 0

- Beweistechniken sind analog zur Mathematik
  - Insbesondere: vollständige Induktion, Beweis durch Widerspruch



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al, MIT Press, 2009

# Asymptotische Laufzeit

- Wie können wir die Effizienz eines Algorithmus unabhängig von Details der Eingabe bewerten?
  - Instanzen (Eingaben) verursachen aufgrund
    - 1. der Größe
    - der individuellen Werte

unterschiedliche physikalische Laufzeiten.

Bsp: Sortieren einer Zahlenfolge

- 1. Wie viele Zahlen sollen sortiert werden?
- 2. In welcher initialen Reihenfolge liegen die Zahlen vor?
- Asymptotische Laufzeit:
  - Wie verhält sich der Algorithmus bei immer größeren Instanzen?
    - im worst case: im ungünstigsten Fall
    - im average case: im statistischen Mittel
    - im best case: im besten Fall
       (bzgl. der Menge aller Instanzen gleicher Länge)
  - Falls nichts weiter angegeben ist, bezieht sich eine Laufzeitanalyse immer auf den Worst Case.

# Asymptotische Laufzeit

#### physikalische Laufzeit

- hängt stark vom Computer ab
- hängt von vielen Details der Eingabedaten ab
- **■** Modellannahmen Laufzeit
  - Uniformes Kostenmaß: Math. Operationen kosten unabhängig von der Größe der Operanden eine Zeiteinheit
  - RAM-Modell (Random-Access-Maschine):
    - Zugriff auf Daten kostet eine konstante Zeiteinheit
    - Algorithmen werden sequentiell ausgeführt (nur ein Prozessor)
  - Statt der genauen Laufzeit wird eine Schranke angegeben
  - Konstante Faktoren werden vernachlässigt.
- Modellannahmen Speicherplatz
  - RAM-Modell: Speicherung eines elementaren Datenobjekts kostet unabhängig vom Wert konstanten Speicherplatz



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al, MIT Press, 2009

18

#### 1.3 O-Notation

## ■ Größenordnungen von Funktionen

f(N)	Bezeichnung	10	1.000	1.000.000
1	konstant	1	1	1
log(N)	logarithmisch	3	10	20
log <sup>2</sup> (N)	log-quadrat	10	100	400
√N		3	30	1000
N	linear	10	1.000	1.000.000
N log(N)		30	10.000	20.000.000
$N^2$	quadratisch	100	1.000.000	10 <sup>12</sup>
$N^3$	kubisch	1000	10 <sup>9</sup>	10 <sup>18</sup>
2 <sup>N</sup>	exponentiell	1000	10 <sup>300</sup>	10 <sup>300000</sup>

Hinweis: zur Berechnung der Beispielzahlen wurde log<sub>2</sub>() verwendet.

#### O-Kalkül / O-Notation

O-Kalkül: Eine Funktion f ist höchstens von der Ordnung g, falls Konstanten c und n₀ existieren mit 0 ≤ f(n) ≤ c g(n) für alle n > n₀, d.h.

 $\exists c > 0 \exists n_0 > 0 \forall n > n_0 : 0 \le f(n) \le c g(n)$ 

- Man schreibt f(n) = O(g(n)).
  - O(g(n)) ist die Menge der Funktionen, die nicht stärker wachsen als g ( = hat die Bedeutung von ∈, mit O ist manchmal eine Menge, manchmal ein Repräsentant gemeint )

0	∃c mit f(n) ≤ c g(n)	f ist höchstens von Ordnung g
0	∀c mit f(n) < c g(n)	f ist von echt kleinerer Ordnung als g
Ω	∃c mit f(n) ≥ c g(n)	f ist mindestens von Ordnung g
ω	∀c mit f(n) > c g(n)	f ist von echt größerer Ordnung als g
Θ	$\exists c_1,c_2 \text{ mit } c_1 g(n) \leq f(n) \leq c_2 g(n)$	f ist von Ordnung g



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al, MIT Press, 2009

21

# O-Notation (O-Kalkül)

#### ■ Rechenregeln für O

- 1. f = O(f)
- 2. f,g = O(F) =>
  - => f + g = O(F)
- 3. f= O(F) und c konstant
- => c \* f = O(F)
- 4. f = O(F) und g = O(f)
- => g = O(F)
- 5. f = O(F) und g = O(G)
- f \* g = O(F \* G)

6. f = O(F \* G)

- => f = |F| \* O(G)
- 7. f = O(F) und  $|F| \le |G|$
- => f = O(G)

#### ■ Beweis zu 5. (andere Beweise erfolgen analog):

- $f(n) = O(F(n)), d.h. \exists n_0, c_0 \forall n \ge n_0 : f(n) \le c_0 F(n)$
- $g(n)=O(G(n)), d.h. \exists n_1, c_1 \forall n \ge n_1 : g(n) \le c_1 G(n)$
- Sei h(n) = f(n) \* g(n). Dann gilt  $\forall$  n  $\geq$  n<sub>2</sub> = max(n<sub>0</sub>,n<sub>1</sub>): f(n) \* g(n)  $\leq$  c<sub>0</sub> F(n) c<sub>1</sub> G(n) = c<sub>2</sub> F(n)G(n), also f \* g = O(F \* G)



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al, MIT Press, 2009 22

#### O-Notation

### ■ Polynome:

- Ist p ein Polynom von Grad m gilt: p = O(N<sup>m</sup>)

# ■ Weitere Beispiele:

- $\blacksquare$  f(n)=3n<sup>2</sup> + 17 $\sqrt{n}$  = O(N<sup>2</sup>)
  - ◆ √n = O(N), Anwendung von Regel 4 und 2
- $\blacksquare$  f(n)= 10<sup>300</sup>n + 2n log(n) = O(N log N)
- $f(n)=2^{2^*n}=(2^2)^n=4^n=O(4^N)$
- $f(n) = \log_{10} n = O(\log N)$ 
  - $\bullet \log_{10} n = \log_2 n / \log_2(10) = 1/\log_2(10) * \log_2 n = O(\log_2 N) = O(\log N)$
  - Eine Änderung der Basis führt zu einem konstanten Faktor, die Basis muss im O-Kalkül nicht berücksichtigt werden.

#### **O-Notation**

# O-Notationen in Gleichungen und Ungleichungen

- 1. Was bedeutet  $2n^2 + 3n + 1 = 2n^2 + \Theta(n)$ ?
  - Θ(n) bezeichnet eine Menge, gemeint ist:

$$2n^2 + 3n + 1 = 2n^2 + f(n)$$
 mit  $f(n) = \Theta(n)$ 


- Θ(n) repräsentiert eine anonyme Funktion, d.h. der genaue Funktionsverlauf ist nicht bekannt, lediglich das Wachstumsverhalten.
- 2. Achtung: O-Notationen in parametrisierten Summen vermeiden!

$$\sum_{i=1}^{n} O(i) \neq O(1) + O(2) + \dots + O(n)$$

- 3. Was bedeutet  $2n^2 + \Theta(n) = \Theta(n^2)$ ?
  - Θ(n) repräsentiert eine anonyme Funktion mit linearem Wachstum f(n)
  - ♦ Für jede Funktion  $f(n) = \Theta(n)$  gibt es eine Funktion  $g(n) = \Theta(n^2)$  und Konstanten  $c_1>0$ ,  $c_2>0$ ,  $n_0>0$  mit

$$c_1 g(n) \le 2n^2 + f(n) \le c_2 g(n)$$
 für alle  $n > n_0$ 

#### Einfluss konstanter Faktoren auf das Funktionswachstum



© Matthias

© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al, MIT Press, 2009

25

27

# 1.4 Laufzeitanalysen

- Gegeben ist ein Algorithmus A mit Eingabe der Länge N Gesucht wird die Laufzeit des Algorithmus: T<sub>A</sub>(N) oder T(N)
- Welche Operation dauert wie lang?

math. Operationen; Zuweisungen
 uniformes Kostenmaß:
 [logarithmisches Kostenmaß:
 O(1)
 O(log x)

x ist der Wert des größten Operanden]

■ Klammerung von Anweisungen O(1)

■ Bedingte Ausführungen O(1)

■ Schleifen O(#Schleifendurchläufe)

■ Funktionsaufrufe O(1)

Rekursion: Aufruf der eigenen Funktion mit

Eingabe der Länge N' T(N')



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al, MIT Press. 2009 26

# Laufzeitanalysen

# ■ Bsp: Berechnung von a<sup>k</sup> für k > 0

EXPONENT (a, k) 
$$b = 1 \qquad c_0$$
 
$$for i = 1 to k \qquad c, k+1 Vergl., k Durchläufe$$
 
$$b = b * a \qquad c_1$$
 
$$return b \qquad c_2$$
 
$$T(a,k) = c_0 + (k+1) * c + k*c_1 + c_2 = O(k)$$

# ■ Bsp: Berechnung von a<sup>k</sup> für k > 0

# Korrektheit von exponent2()

- Schleifeninvariante: a<sup>k</sup> = p \* q<sup>l</sup>
- Beweis der Korrektheit:
  - Vor Schleifenbeginn (Zeile 2) gilt:

$$p=1, q=a, l=k => a^k = p * q^l$$

■ Nach jedem Schleifendurchlauf (nach Zeile 6) gilt:

vor Zeile 3 gilt  $a^k = p * q^l$  (Schleifeninvariante)

Fall 1: I ist gerade, d.h. I mod 2 = 0

Seien I' und q' die Werte von I und q vor Zeile 4. Dann gilt nach

Zeile 6:  $a^k = pq^{l} = p(q^2)^{l/2} = pq^l$ 

Fall 2: I ist ungerade, d.h. I mod 2 = 1

Seien p', l', q' die Werte von p, l, und q vor Zeile 4, Dann gilt nach Zeile 6:  $a^k = p'q'^l = p'q'(q'^2)^{(l'-1)/2} = p'q'q^l = pq^l$ 

■ Nach Schleifenende (Zeile 7) gilt:

 $a^k = p * q^l$  und l=0 (Schleifenterminierung), also  $a^k = p$ 

# 1.5 Asymptotische Laufzeit rekursiver Funktionen

- Rekurrenz: Gleichung/Ungleichung, die durch sich selbst mit kleinerem Eingabewert beschrieben wird:
- Bsp:

$$T(n) = \begin{cases} c_0 & : n = 1 \\ T(n-1) + c_1 & : n > 1 \end{cases}$$

$$T(n) = \begin{cases} c & : n = 1\\ 2T(n/2) + c & : n > 1 \end{cases}$$

- Eigenschaften:
  - T(n) ist typischerweise nur für n ∈IN definiert
  - T(n) = c für kleine n
  - Auf- und Abrundungen für n können i.d.R. vernachlässigt werden.
- Ziel:
  - 1. bestimme die asymptotische Laufzeit
  - 2. finde eine geschlossene Formel für T(n)



© Matthias Rarey, ZBH, Universität Hamburg

escannte Abbildungen: © Cormen et a MIT Press, 2009

#### Substitutionsmethode

#### ■ Schritt 1: Setze T(n) wiederholt ein:

$$T(n) = T(n-1) + c_1$$

$$= T(n-2) + c_1 + c_1$$

$$= T(n-(n-1)) + \underbrace{c_1 + c_1 \cdots + c_1}_{n-1 \text{ mal}}$$

$$= T(1) + (n-1)c_1 = (n-1)c_1 + c_0 = O(n)$$

$$T(n) = 2T(n/2) + c$$

$$= 2(2T(n/4) + c) + c$$

$$= 4T(n/4) + 2c + c$$

$$= 2^{i}T(n/2^{i}) + 2^{i-1}c + 2^{i-2}c + \dots + c$$



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al, MIT Press. 2009

30

### Substitutionsmethode

#### Schritt 2: Intuition

$$T(n) = 2^{i} T(n/2^{i}) + 2^{i-1} c + 2^{i-2} c + \dots + c$$
$$= 2^{i} T(n/2^{i}) + \sum_{k=0}^{i-1} 2^{k} c$$

■ Wie viele Substitutionsschritte sind notwendig?

$$n/2^{i} \le 1 \Leftrightarrow n \le 2^{i} \Leftrightarrow \log_{2} n \le i$$

$$T(n) = 2^{i}T(n/2^{i}) + c\sum_{k=0}^{i-1} 2^{k} \qquad \text{mit } i = \log_{2} n$$

$$= 2^{\log_{2} n}T(1) + c\sum_{k=0}^{\log_{2} n-1} 2^{k} \qquad \text{Geometrische / Exponentielle Reihe :}$$

$$= nc + c(2^{\log_{2} n} - 1) = nc + c(n-1) = 2cn - c = O(n)$$

■ Beweis erfolgt durch vollständige Induktion

# Substitutionsmethode

- Schritt 3: Beweis der Hypothese (durch vollständige Induktion)
  - Annahme: T(n) ≤ kn
  - Induktionsanfang:  $T(1) = c \le k*1$  für  $k \ge c$
  - Induktionsschritt:

$$T(n) = 2T(n/2) + c \le 2kn/2 + c \le kn + c$$



- Neue Annahme: T(n) ≤ kn c
- Induktionsanfang:  $T(1) = c \le k*1 c$  für  $k \ge 2c$
- Induktionsschritt:

$$T(n) = 2T(n/2) + c \le 2(kn/2 - c) + c \le kn - c$$

In der Regel werden wir unserer Intuition vertrauen, formal ist der Beweis aber notwendig.

### Hilfsmittel: Variablentransformation

- Transformation der Variablen hilft häufig, einfachere, intuitiv leichter lösbare Gleichungen zu erhalten:
- Bsp:

$$T(n) = 2T \left( \sqrt{n} \right) + \log n$$

■ Ersetze m = log n

$$T(n) = 2T\left(\sqrt{2^{\log n}}\right) + \log n$$
$$T(2^m) = 2T\left(2^{m/2}\right) + m$$

■ Setze S(m) = T(2<sup>m</sup>)

$$S(m) = 2S(m/2) + m = O(m \log m)$$

$$T(n) = O(\log n \log \log n)$$

UHI #

© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al.

### Hilfsmittel: Rekursionsbaum

- Was tun, wenn die Intuition fehlt?
  - Aufbau des Rekursionsbaums
  - Abschätzung der Höhe, der Knoten pro Ebene, der Kosten pro Knoten
- **Bsp:**  $T(n) = 3T(n/4) + cn^2$

$$= cn^{2} + \frac{3}{16}cn^{2} + \left(\frac{3}{16}\right)^{2}cn^{2} + \dots + \left(\frac{3}{16}\right)^{\log_{4}n - 1}cn^{2} + \Theta(n^{\log_{4}3})$$

$$= \sum_{i=0}^{\log_{4}n - 1} \left(\frac{3}{16}\right)^{i}cn^{2} + \Theta(n^{\log_{4}3})$$

$$\leq \sum_{i=0}^{\infty} \left(\frac{3}{16}\right)^{i}cn^{2} + \Theta(n^{\log_{4}3})$$

$$= \frac{1}{1 - (3/16)}cn^{2} + \Theta(n^{\log_{4}3})$$


$$= O(n^{2})$$
Unendl. Geom. / Exp. Reihe:
$$\sum_{k=0}^{\infty} x^{k} = \frac{1}{1 - x} \quad \text{für } x \in IR, |x| < 1$$

$$= O(n^{2})$$

#### Hilfsmittel: Rekursionsbaum

#### ■ Was tun, wenn die Intuition fehlt?

- Aufbau des Rekursionsbaums
- Abschätzung der Höhe, der Knoten pro Ebene, der Kosten pro Knoten



UHI (

© Matthias Rarey, ZBH, Universität Hamburg

scannte Abbildungen: © Cormen et al, MIT Press, 2009 34

#### Das Master-Theorem

# Auflösung von Rekurrenzen der Form

$$T(n) = \begin{cases} c & : n = 1\\ aT(n/b) + f(n) & : n > 1 \end{cases}$$

# mit $a \ge 1$ und b > 1, a und b konstant

- Algorithmische Bedeutung:
  - Ein Problem wird in a Teilprobleme zerlegt
  - Jedes Teilproblem hat die Größe n/b (genauer [n/b])
  - Zum Aufteilen des Problems und zum Zusammenfügen benötigt man f(n) Zeit.

Fall 1. 
$$f(n) = O(n^{\log_b a - \varepsilon}), \varepsilon > 0$$
 :  $T(n) = \Theta(n^{\log_b a})$ 
Fall 2.  $f(n) = \Theta(n^{\log_b a})$  :  $T(n) = \Theta(n^{\log_b a})$ 
Fall 3.  $f(n) = \Omega(n^{\log_b a + \varepsilon}), \varepsilon > 0$  :  $T(n) = \Theta(f(n))$ 

#### Das Master-Theorem

Bsp:

$$T(n) = \begin{cases} c & : n = 1\\ 2T(n/2) + c & : n > 1 \end{cases}$$

$$a = 2, b = 2, f(n) = c$$

■ Welcher Fall des Master Theorems?

$$\log_b a = 1$$
 für  $a = b = 2$  und  $f(n) = c = O(n^{1-\varepsilon})$ 

■ Die Bedingungen für Fall 1 sind erfüllt, also folgt

$$T(n) = \Theta(n^{\log_b a}) = \Theta(n)$$



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al,

# 1.6 Ein Beispiel: Das Maximum-Subarray-Problem

[aus Ottmann, Widmeyer, Algorithmen und Datenstrukturen, Spektrum Verlag, 2002]

- Problem (maximum-subarray):
  - geg.: eine Folge X von N ganzen Zahlen
  - ges.: Teilfolge, deren Summe maximal ist (max. Teilsumme)
- Bsp.:
  - N=10, X: 3, -4, 5, 2, -5, 6, 9, -9, -2, 8 (d.h. X[1]=3, X[2]=-4, ...)
  - Teilsumme von X[1..4]: 3-4+5+2 = 6
  - max. Teilsumme X[3..7]: 5+2-5+6+9 = 17
- Algorithmus 1: Probiere alle Möglichkeiten
  - u: untere Grenze der Teilsumme
  - o: obere Grenze der Teilsumme
  - tsum: aktuelle Teilsumme
  - maxtsum: maximale Teilsumme



© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al,

# Das Maximum-Subarray-Problem

Algorithmus 1: Probiere

$$\begin{tabular}{llll} TEILSUMME(X) & Zeitbedarf \\ maxtsum = 0 & c \\ for u = 1 to X.length & N \\ for o = u to X.length & N-u+1 & \leq N \\ tsum = 0 & c \\ for i = u to o & o-u+1 & \leq N \\ tsum = tsum+X[i] & c \\ maxtsum = max( maxtsum, tsum) & c \\ return maxtsum & c \\ \hline \end{tabular}$$


■ Laufzeit: Sei N = X.length die Anzahl der Array-Elemente.

Offensichtlich gilt  $T_n(N) = O(N^3)$ .

Es gilt sogar  $T_n(N) = \Theta(N^3)$  (ohne Beweis).

# Das Maximum-Subarray-Problem

- Verbesserung 1: Divide & Conquer Verfahren (Teile und Herrsche)
- Idee:
  - Teile die Folge in linke und rechte Hälfte L, R an der Stelle N/2
  - Fall 1: max. Teilsumme ist in L
  - Fall 2: max. Teilsumme ist in R
  - Fall 3: max. Teilsumme enthält X[[N/2]] und X[[N/2]+1]



■ Teilproblem: maximale Randteilsumme

```
RTS_links(X,1,r)
  // finde max. Randteilsumme am linken Rand in
 X[1,...,r]
 lmax = 0; sum = 0;
 for i = 1 to r
    sum = sum + X[i]
    lmax = max( lmax, sum )
 return lmax
```

Laufzeit:  $T_{RTS}(N) = O(N)$ 



### Das Maximum-Subarray-Problem

■ Algorithmus 2: Divide&Conquer (Aufruf Teilsumme(X,1,X.length))

TEILSUMME(X,1,r)

if l == r

return max(X[1],0)
else// DIVIDE: Teile die Daten
m = |(1+r)/2|

// CONQUER: Löse Teilprobleme

maxtsum Mitte)

Fall 1: maxtsum\_Links =Teilsumme(X,1,m)
Fall 2: maxtsum\_Rechts = Teilsumme(X,m+1,r)

// MERGE: Füge Ergebnis zusammen
maxtsum = max( maxtsum\_Links, maxtsum\_Rechts,

return maxtsum

UHI #

© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al, MIT Press, 2009

maxtsum

4

С

С

 $T_{DC}(N/2)$ 

 $T_{DC}(N/2)$ 

### Das Maximum-Subarray-Problem

Rekurrenz für Divide&Conquer:

$$T_{DC}(N) = \begin{cases} c & : N = 1\\ 2T_{DC}(N/2) + cN & : N > 1 \end{cases}$$

■ Master-Theorem: a = b = 2; f(N) = c N = O(N)

$$\mathsf{T}_{\mathsf{DC}}(\mathsf{N}) = \Theta(\;\mathsf{N}\;\mathsf{log}\;\mathsf{N}\;)$$

- Wie viel Zeit benötigt man mindestens zur Lösung des Problems?
  - Man muss jedes X[i] mindestens ein mal betrachten
  - $\blacksquare$   $\mathsf{T}_{\mathsf{opt}}(\mathsf{N}) = \Omega(\mathsf{N})$




© Matthias Rarey, ZBH, Universität Hamburg

gescannte Abbildungen: © Cormen et al, MIT Press, 2009 42

# Das Maximum-Subarray-Problem

- Verbesserung 2: Scan-Line Verfahren
- Idee:
  - durchlaufe X von links nach rechts
  - merke dir das bisherige Maximum
  - merke dir die rechte Randteilsumme maxtsum\_RRand



- Scan-Line am linken Rand: maxtsum = maxtsum RRand= 0
- Scan-Line geht von i nach i+1:
  - maxtsum\_RRand: addiere X[i+1]; setze auf 0 falls negativ
  - maxtsum: Maximum von maxtsum oder maxtsum\_RRand
- Scan-Line ist rechts angekommen: maxtsum ist das Ergebnis

# Das Maximum-Subarray-Problem

■ Algorithmus 3: Scan-Line-Verfahren

$$T_{SL}(N) = c N = \Theta(N)$$

■ Das Scan-Line Verfahren löst das Maximum-Subarray-Problem in optimaler asymptotischer Laufzeit.