

Kapitel 3: Sortieren

Elementare Sortieralgorithmen

Heaps und Heapsort

Quicksort

Eine untere Schranke für das Sortierproblem

Counting-, Radix- und Bucketsort

Algorithmen für Auswahlprobleme

3.1 Elementare Sortieralgorithmen

- Problem:
 - Geg. Menge von Datensätzen s_i mit Schlüsseln k_i .
 - Geg. totale Ordnungsrelation \leq
 - Ges.: Permutation π mit: $k_{\pi(1)} \leq k_{\pi(2)} \leq \dots \leq k_{\pi(n)}$
- partielle Ordnung R:
 - reflexiv: es gilt $a R a$
 - antisymmetrisch: $a R b$ und $b R a$ folgt $a = b$
 - transitiv: $a R b$ und $b R c$ folgt $a R c$
- totale Ordnung R:
 - R ist partielle Ordnung
 - für alle a, b gilt: $a R b$ oder $b R a$
- Bsp: Ordnung auf der Menge der Menschen
 - $R = \text{'ist Nachfahre von'}$ partiell (und nicht reflexiv)
 - $R = \text{'hat größere Ausweisnummer'}$ nicht reflexiv!
 - $R = \text{'hat keine kleinere Ausweisnummer'}$ total

Elementare Sortialgorithmen

- Für alle Sortialgorithmen

- Datentyp:

- ```
struct item
{
 key : integer
 info: Grundtyp
}
```

- Eingabe: A: array[1...N] of item

- Ausgabe: A mit vertauschten Einträgen, so dass  
 $A[i] \leq A[i+1]$  für  $1 \leq i < N$  gilt.

- Laufzeitanalyse:

- ◆ Zugriffsoperation  $c_Z$

- ◆ Vergleichsoperationen  $c_V$

- ◆ Datenaustauschoperationen  $c_D$

- ◆ ggf. ist  $c_D \gg c_V$ : Sortieren der Schlüssel, anschließend Datenaustausch

# Sortieren durch Auswahl

## ■ Idee:

### ■ Iteriere von 1 bis N-1:

im i-ten Durchlauf: Schreibe das kleinste Element aus  $A[i..n]$  an Position  $A[i]$

```
SELECTION-SORT(A)
for i = 1 to A.length-1
// suche kleinstes Element aus A[i..N]
 min = i
 for j = i+1 to A.length
 if(A[j] < A[min]) min= j
// vertausche A[i] und A[min]
 SWAP(A[min], A[i])
```

```
SWAP(a,b)
t = a; a = b; b = t
```

### ■ Laufzeit: $T(N) = \Theta(N^2)$

### ■ nur $O(N)$ Datenaustausche

|        |        |        |    |          |   |    |          |   |
|--------|--------|--------|----|----------|---|----|----------|---|
| index: | 1      | 2      | 3  | 4        | 5 | 6  | 7        | 8 |
| A:     | 3      | 8      | 14 | 2        | 9 | 23 | 1        | 4 |
|        | ↑<br>i |        |    |          |   |    | ↑<br>min |   |
| A:     | 1      | 8      | 14 | 2        | 9 | 23 | 3        | 4 |
|        |        | ↑<br>i |    | ↑<br>min |   |    |          |   |
| A:     | 1      | 2      | 14 | 8        | 9 | 23 | 3        | 4 |
|        |        |        |    | ⋮        |   |    |          |   |
|        |        |        |    | ⋮        |   |    |          |   |
|        |        |        |    | ⋮        |   |    |          |   |

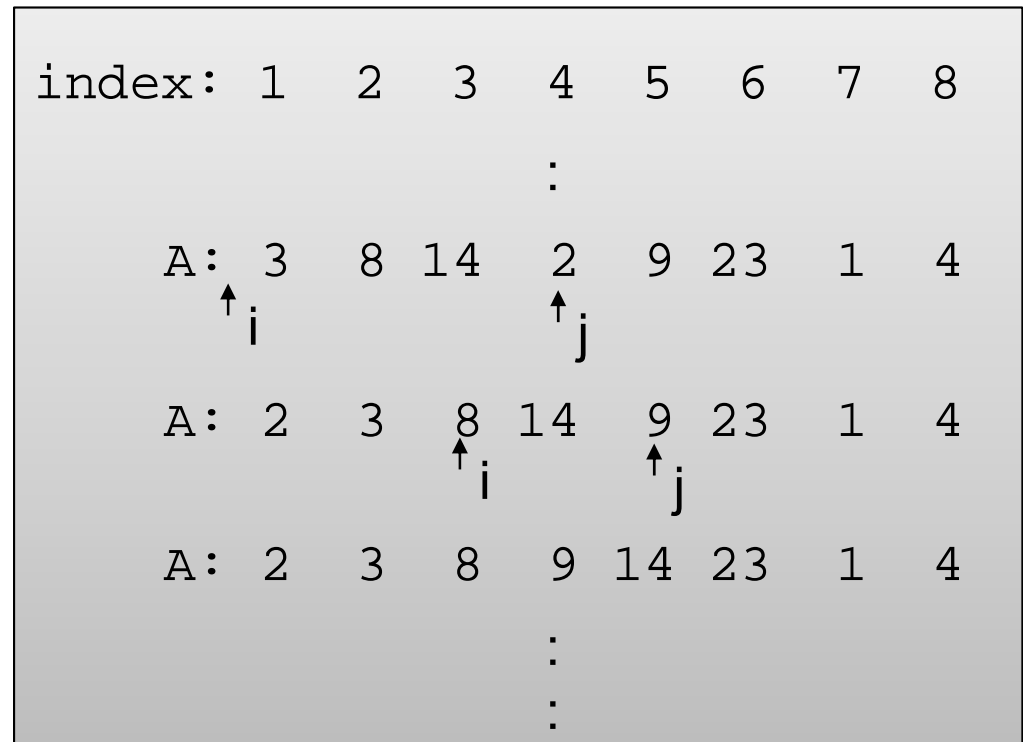
# Sortieren durch Einfügen

## ■ Idee:

### ■ Iteriere von 2 bis N:

im j-ten Durchlauf: Füge das j-te Element in die sortierte Folge  $A[1 \dots j-1]$  ein

```
INSERTION-SORT(A)
for j = 2 to A.length
 key ← A[j]
 // setze A[j] sortiert in A[1..j-1] ein
 i = j-1
 while i > 0 and A[i] > key
 A[i+1] = A[i]
 i = i-1
 A[i+1] = key
```




## ■ Laufzeit (im Worst Case): $T(N) = \Theta(N^2)$

# Bubblesort

## ■ Idee:

- Iteriere solange, bis keine Vertauschung mehr durchgeführt wird:  
im i-ten Durchlauf (for-Schleife): bringe Minimum von  $A[i..N]$  an  
Position  $A[i]$  durch sukzessives Vertauschen benachbarter Elemente

```
BUBBLESORT(A)
for i = 1 to A.length
 noswap = TRUE
 for j = A.length downto i+1
 if A[j] < A[j-1]
 SWAP(A[j], A[j-1])
 noswap = FALSE
 if(noswap) break
```



- Laufzeit (im Worst Case):  $T(N) = \Theta(N^2)$

# Mergesort

- Idee: Divide & Conquer

- Teile die Folge in zwei Teilfolgen  $L = A[1..\lfloor N/2 \rfloor]$ ,  $R = A[\lfloor N/2 \rfloor + 1..N]$

- Sortiere L und R

- Verschmelze sortierte Folgen L und R zu einer sortierten Folge

```
MERGE-SORT(A, l, r)
```

```
 if l < r
```

```
 m = floor((l+r)/2)
```

```
 MERGE-SORT(A, l, m)
```


```
 MERGE-SORT(A, m+1, r)
```

```
 MERGE(A, l, m, r)
```


|          | L |   |    |    | R |    |    |    |
|----------|---|---|----|----|---|----|----|----|
| index:   | 1 | 2 | 3  | 4  | 5 | 6  | 7  | 8  |
| Divide:  |   |   |    |    |   |    |    |    |
| A:       | 3 | 8 | 14 | 2  | 9 | 23 | 1  | 4  |
| Conquer: |   |   |    |    |   |    |    |    |
| A:       | 2 | 3 | 8  | 14 | 1 | 4  | 9  | 23 |
| Merge:   |   |   |    |    |   |    |    |    |
| A:       | 1 | 2 | 3  | 4  | 8 | 9  | 14 | 23 |

## 2-Wege Merge-Operation


- Merge-Operation (mit Listen)
  - geg.: zwei aufsteigend sortierte Listen L und R
  - ges.: eine aufsteigend sortierte Liste A aus L und R



Fall 1:  $L.head < R.head$   
oder  $EMPTY(R)$



Fall 2:  $L.head > R.head$   
oder  $EMPTY(L)$





## 2-Wege Merge-Operation

---

- Listenoperationen:

- INIT: initialisiere leere Liste      EMPTY: wahr, falls Liste leer
- head: erstes Element der Liste      TAIL: Liste ohne erstes Element
- APPEND: einfügen am Ende der Liste

- MERGE-LISTS(L,R : list)

```
A = INIT()
```

```
while not (EMPTY(L) and EMPTY(R))
```

```
 if EMPTY(R) or L.head ≤ R.head
```

```
 APPEND(A, L.head)
```

```
 L = TAIL(L)
```

```
 elseif EMPTY(L) or L.head ≥ R.head
```

```
 APPEND(A, R.head)
```

```
 R ← TAIL(R)
```

```
return A
```

Laufzeit:  $O(|L|+|R|)$

## 2-Wege Merge-Operation mit Arrays

```

procedure merge (var a : sequence; l, m, r : integer);
 {verschmilzt die beiden sortierten Teilfolgen a[l]...a[m]
 und a[m+1]...a[r] und speichert sie in a[l]...a[r]}
var
 b : sequence; {Hilfsfeld zum Verschmelzen}
 h, i, j, k : integer;
begin
 i := l; {inspiziere noch a[i] bis a[m] der ersten Teilfolge}
 j := m + 1; {inspiziere noch a[j] bis a[r] der zweiten Teilfolge}
 k := l; {das nächste Element der Resultatfolge ist b[k]}
 while (i ≤ m) and (j ≤ r) do
 begin {beide Teilfolgen sind noch nicht erschöpft}
 if a[i].key ≤ a[j].key
 then {übernimm a[i] nach b[k]}
 begin
 b[k] := a[i];
 i := i + 1;
 end
 else {übernimm a[j] nach b[k]}
 begin
 b[k] := a[j];
 j := j + 1;
 end;
 k := k + 1;
 end;
 if i > m
 then {erste Teilfolge ist erschöpft; übernimm zweite}
 for h := j to r do b[k + h - j] := a[h]
 else {zweite Teilfolge ist erschöpft; übernimm erste}
 for h := i to m do b[k + h - i] := a[h];
 {speichere sortierte Folge von b zurück nach a}
 for h := l to r do a[h] := b[h]
 end
 end

```

- Liste L: a[l....m]    Liste R: a[m+1...r]
- Liste A: zunächst in b,  
wird abschließend kopiert nach a
- i: index von L.head
- j: index von R.head
- k: index von A.rear
- ... APPEND(...)
- ... TAIL(...)
- andere Schleifenstruktur:
  - ◆ Teil 1: beide Listen nicht leer
  - ◆ Teil 2: Liste L leer
  - ◆ Teil 3: Liste R leer
- Kopieren von b nach a

# Laufzeit Mergesort

---

## ■ Mergesort

1. Teile die Folge in zwei Teilfolgen  
 $L = A[1 \dots \lceil n/2 \rceil], R = A[\lceil n/2 \rceil + 1 \dots n]$   $O(1)$
2. Sortiere L und R  $2 * T(N/2)$
3. Verschmelze sortierte Folgen L und R zu einer sortierten Folge  $O(N)$

■ Laufzeit:  $T(N) = 2 * T(N/2) + cN = O(N \log N)$

■ Speicherbedarf:

- Array A:  $c * N$
- Zwischenspeicherung in zweitem Array:  $c * N$
- doppelter Speicherbedarf!

■ k-Wege Mergesort: Teile und Verschmelze k Teilfolgen




Laufzeit:  $T(N) = k * T(N/k) + c k N = O(N \log N)$

( $k * N$ , da in jeder Iteration das Minimum aus k  
Listenköpfen bestimmt werden muss)

## 3.2 Heaps und Heapsort

---

- Sortieren durch Auswahl (siehe 3.1)
  - das kleinste Element wird ausgewählt und an die bereits sortierte Liste angehängt
  - Wie gestaltet man den Auswahlschritt?
- Neue Datenstruktur: Heap
  - ‚Objekte liegen auf einer Halde, ein Objekt ist immer mindestens so groß wie die darunter liegenden Objekte‘ (Heap-Bedingung)
  - Operationen:
    - ◆ BUILD-MAX-HEAP: baue eine Halde aus einer Menge von Elementen
    - ◆ HEAP-EXTRACT-MAX: nehme das größte Element von der Halde
      - ◆ MAX-HEAPIFY: stelle die Heap-Bedingung nach Entnahme wieder her



# Der Heapsort-Algorithmus

## ■ HEAPSORT-WITH-HEAP(A)

// Heapsort mit HEAP-Datenstruktur

H = INIT()

for i = 1 to A.length

HEAP-INSERT(H, A[i] )

for i = A.length downto 1

A[i] = HEAP-EXTRACT-MAX(H)

■ füge alle Elemente in den Heap ein (Zeit  $T_{\text{build}}(N)$ )

■ entnehme das größte Element (und stelle die Heap-Eigenschaft wieder her) (Zeit  $T_{\text{xmax}}(N)$ )

## ■ HEAPSORT(A)

// Heap mit i Elementen steht im

// Array A[1..i], A[1] enthält das

// Maximum

BUILD-MAX-HEAP(A)

heap\_size[A] = A.length

for i = A.length downto 2

SWAP( A[i], A[1] )

A.heap\_size = A.heap\_size - 1

MAX-HEAPIFY(A,1)


## ■ Laufzeit:

■  $T(N) = O(T_{\text{build}}(N) + N T_{\text{xmax}}(N))$

# Der Heap

## ■ Der Heap basiert auf einer *binären Baumstruktur*:


- ◆ jeder Knoten  $i$  hat bis zu zwei Nachfolger  $\text{LEFT}(i)$ ,  $\text{RIGHT}(i)$
- ◆ alle bis auf ein Knoten haben genau einen Vorgänger  $\text{PARENT}(i)$
- ◆ jeder Knoten speichert ein Element  $A[i]$



## ■ **Heap-Eigenschaft:**

Max-Heap:  $\forall$  Knoten  $i$  außer der Wurzel:  
 $A[\text{PARENT}(i)] \geq A[i]$

Min-Heap:  $\forall$  Knoten  $i$  außer der Wurzel:  
 $A[\text{PARENT}(i)] \leq A[i]$



# Der Heap

- Ein Heap kann durch ein Array repräsentiert werden:

- $\text{PARENT}(i) = i \text{ div } 2$

- $\text{LEFT}(i) = 2 * i$

- $\text{RIGHT}(i) = 2 * i + 1$

- Begriffe: Sei A ein Heap


- *Höhe von A*: max Anzahl Knoten auf dem direktem Weg zu einem Blatt

- A.heap\_size: Anzahl Elemente in A

- Weitere Eigenschaften:

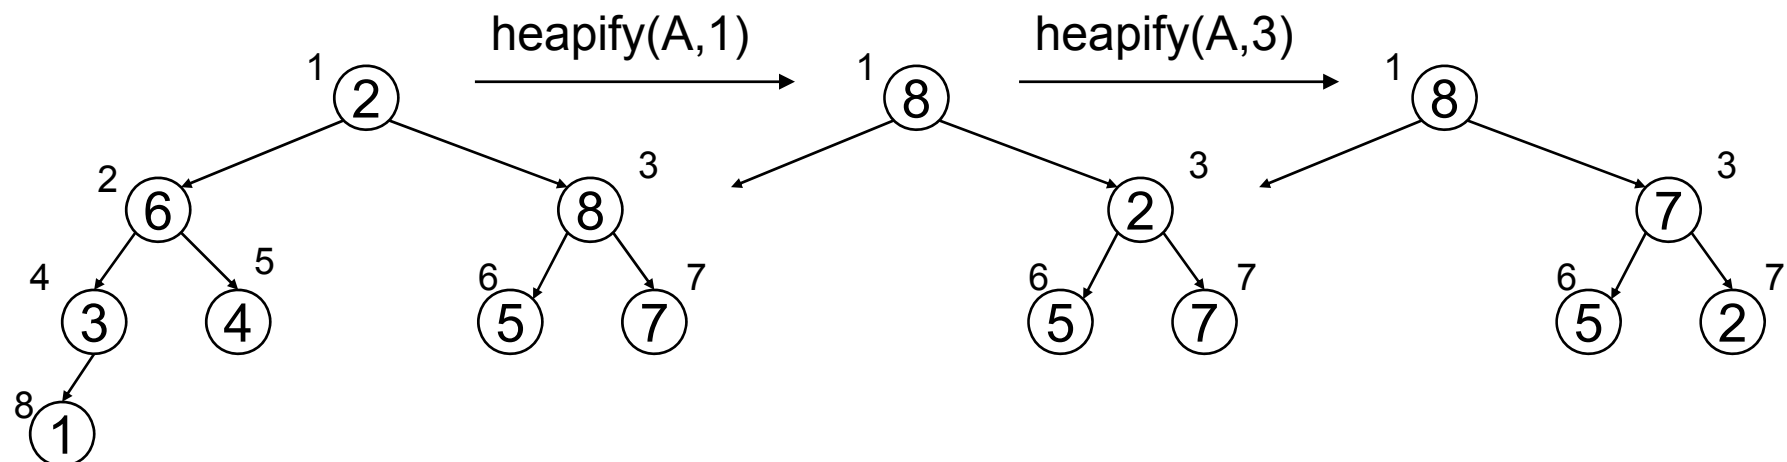
- Ein Heap der Größe N hat max. Höhe:  $\lfloor \log_2 N \rfloor$

- auf Ebene i liegen  $2^i$  Knoten



# Die MAX-HEAPIFY-Operation

- Heap-Eigenschaft (top-down): Sei A ein Heap, dann gilt
  - $A[i] \geq A[\text{LEFT}(i)]$  und  $A[i] \geq A[\text{RIGHT}(i)]$
- Heapify (Versickern):
  - Annahme: A erfüllt Heap-Eigenschaft bis auf in einem Teilbaum unter Position i
  - MAX-HEAPIFY(A,i): repariert den Heap (stellt die Heap-Eigenschaft wieder her)



HEAPIFY: - bestimme direkten Nachfolger c mit max. Wert  $A[c]$   
- vertausche  $A[i]$  mit  $A[c]$   
- HEAPIFY(A, c)



# Die MAX-HEAPIFY-Operation

## ■ MAX-HEAPIFY( $A, i$ )

```
if(LEFT(i) ≤ A.heap_size and
 A[LEFT(i)] > A[i])
 c = LEFT(i)
else c = i
if(RIGHT(i) ≤ A.heap_size and
 A[RIGHT(i)] > A[c])
 c = RIGHT(i)
if c ≠ i
 SWAP(A[i], A[c])
 MAX-HEAPIFY(A, c)
```

$c$ : Index des größten Elements aus der Menge  $i$ ,  $\text{left}(i)$ ,  $\text{right}(i)$  innerhalb von  $A$

$\text{heap\_size}[A]$ : Größe des Heaps, nicht die Anzahl der Elemente des Arrays!

$c = i$ : Heap-Eigenschaft war nicht verletzt  
 $c \neq i$ : vertausche Elemente  $c$  und  $i$

## ■ Laufzeit:

$$T_{\text{heapify}}(n) = T_{\text{heapify}}(2n/3) + \Theta(1)$$

Master-Theorem, Fall 2:

$$T_{\text{heapify}}(n) = O(\log(n))$$



# Laufzeit der MAX-HEAPIFY-Operation

## ■ Rekurrenzgleichung:


Im Worst-Case gilt:  $T_{\text{heapify}}(n) = T_{\text{heapify}}(2n/3) + \Theta(1)$

## ■ Beweis:


- Betrachte zunächst einen vollständigen binären Baum B der Höhe  $k = \lfloor \log_2 n \rfloor + 1$ :

Sei N die Anzahl der Knoten von B, dann gilt:

- ◆ B hat  $N = 2^k - 1$  Knoten
- ◆ B hat  $(N+1)/2$  Blätter
- ◆ B hat  $(N-1)/2$  Knoten in jedem Teilbaum unter der Wurzel



Bsp:



$n = 5$   
 $k = 3$   
 $N = 7$

# Laufzeit der MAX-HEAPIFY-Operation

## ■ Beweis (Fortsetzung):

Worst Case: MAX-HEAPIFY verzweigt in den größeren Teilbaum (links) mit insgesamt  $n_L$  Knoten:  $T_{\text{heapify}}(n) = T_{\text{heapify}}(n_L) + \Theta(1)$

Wie groß ist  $n_L$  in Bezug zur Gesamtzahl der Knoten  $n$  im Worst Case?

$$n_L = \frac{N-1}{2}$$

$$n_R = \frac{N-1}{2} - \frac{N+1}{4} = \frac{N-3}{4}$$


$$n = 1 + n_L + n_R$$

$$= 1 + \frac{N-1}{2} + \frac{N-1}{2} - \frac{N+1}{4}$$


$$= \frac{3N-1}{4}$$

$$\Leftrightarrow N = \frac{4n+1}{3}$$

$$\Rightarrow n_L = \frac{N-1}{2} = \frac{\frac{4n+1}{3} - 1}{2} = \frac{2}{3}n - \frac{1}{3} \leq \frac{2}{3}n$$



Bsp:



$n = 5$   
 $k = 3$   
 $N = 7$

# Die HEAP-EXTRACT-MAX-Operation

## ■ HEAP-EXTRACT-MAX:

Entnahme des maximalen Element aus dem Heap

## ■ HEAP-EXTRACT-MAX(A)

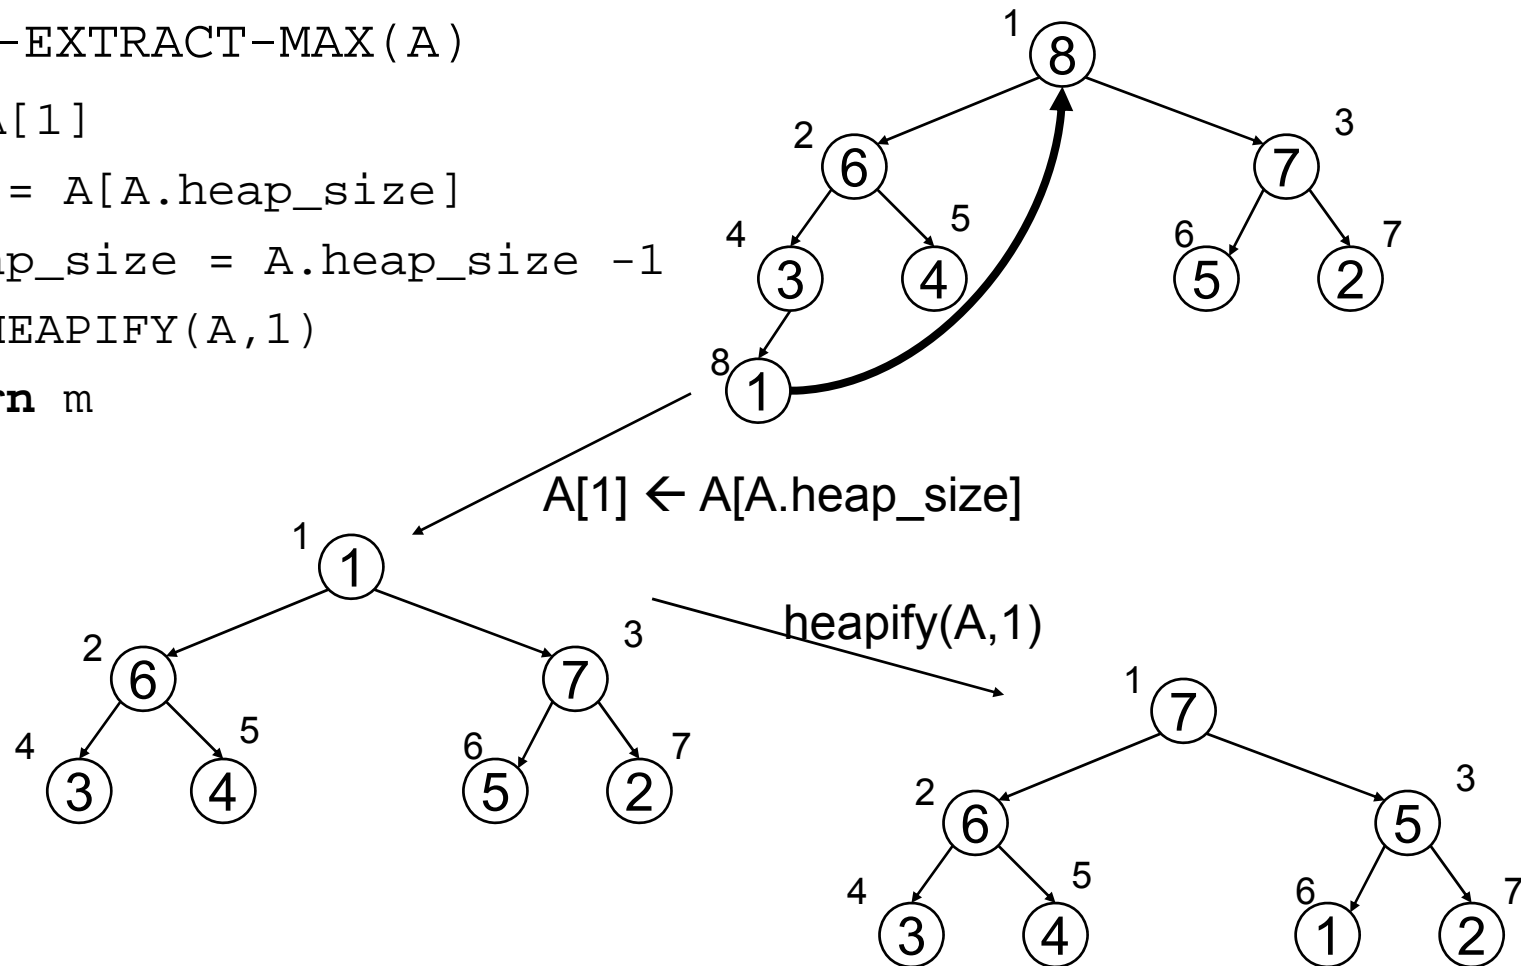
$m = A[1]$

$A[1] = A[A.\text{heap\_size}]$

$A.\text{heap\_size} = A.\text{heap\_size} - 1$

MAX-HEAPIFY(A, 1)

**return** m



# Die BUILD-MAX-HEAP-Operation


## ■ BUILD-MAX-HEAP:

■ Eingabe: unsortiertes Array A

■ Ausgabe: Heap (als Array in A)

■ Idee:

- ◆ Elemente  $\lfloor A.\text{heap\_size}/2 \rfloor + 1 - A.\text{heap\_size}$  (die Blätter) sind ein-elementige Heaps
- ◆ Verwende MAX-HEAPIFY um den Heap von unten nach oben aufzubauen



# Die BUILD-MAX-HEAP-Operation

---

■ `BUILD-MAX-HEAP(A)`  
    `A.heap_size ← A.length`  
    **for** `i ← ⌊A.heap_size/2⌋ downto 1`                       $n/2$  Durchläufe  
        `MAX-HEAPIFY(A, i)`                                       $O(\log n)$

■ Korrektheit von BUILD-MAX-HEAP:

Schleifeninvariante:  $\forall k \in \{i+1, \dots, n=A.length\}$ :  $A[k]$  ist die Wurzel eines Max-Heaps.

■ Initialisierung:

◆ Knoten  $A[\lfloor n/2 \rfloor + 1], A[\lfloor n/2 \rfloor + 2], \dots, n$  sind Blätter und erfüllen somit die Max-Heap-Eigenschaft.

■ Fortsetzung: Für Knoten  $i$  gilt:

◆  $LEFT(i)$  und  $RIGHT(i)$  sind Max-Heaps wg. der Schleifeninvariante  
◆  $MAX-HEAPIFY(A, i)$  stellt somit die Max-Heap-Eigenschaft her.

■ Terminierung:

◆ Schleife terminiert mit  $i=0$ , damit in  $A[1]$  die Wurzel eines Max-Heap.

# Die BUILD-MAX-HEAP-Operation

- Laufzeit von BUILD-MAX-HEAP(A)

Sei  $n = A.length$ , offensichtlich gilt  $T_{\text{build}}(n) = O(n \log n)$ .

- Gilt auch  $T_{\text{build}}(n) = \Theta(n \log n)$ ?

- Laufzeit ist proportional zur akkumulierten Laufzeit der MAX-HEAPIFY-Operationen

- MAX-HEAPIFY für einen Knoten mit Höhe  $h$ :  $O(h)$

- Höhe variiert von  $h=0$  bis  $\lfloor \log n \rfloor$

- Anzahl Knoten mit Höhe  $h$ :  $\lceil n / 2^{h+1} \rceil$

(Anzahl Knoten halbiert sich von Ebene zu Ebene)

$$T(n) = c \sum_{h=0}^{\lfloor \log n \rfloor} \left\lceil \frac{n}{2^{h+1}} \right\rceil h = O\left(n \sum_{h=0}^{\log n} \frac{h}{2^h}\right) = O(n)$$

$$\text{mit } \sum_{h=0}^{\infty} \frac{h}{2^h} = \sum_{h=0}^{\infty} h \left(\frac{1}{2}\right)^h = \frac{1/2}{\left(1 - 1/2\right)^2} = 2$$

(Ableitung der geom. Reihe, siehe Cormen A.8)

# Prioritätswarteschlangen (Priority Queues)

---

- Priority Queue:

- Ziel: Warteschlange mit Prioritäten

- Operationen:

- ◆ HEAP-INSERT( $A, x$ ): füge ein Element  $x$  in die Warteschlange  $A$  ein

- ◆ HEAP-EXTRACT-MAX( $A$ ): entnehme das Element mit max. Priorität

- ◆ HEAP-INCREASE-KEY( $A, i, k$ ): erhöhe den Wert von Schlängenelement Nummer  $i$  auf  $k$ ,  $k > A[i]$

- ◆ HEAP-DECREASE-KEY( $A, i, k$ ): verringert den Wert von Schlängenelement Nummer  $i$  auf  $k$ ,  $k < A[i]$

- Realisierung: durch einen Heap

- ◆ HEAP-EXTRACT-MAX-Operation: wie zuvor, Laufzeit  $O(\log N)$

- ◆ HEAP-DECREASE-KEY-Operation: wie MAX-HEAPIFY, Laufzeit  $O(\log N)$

Achtung:

- Typo im Cormen S. 135: INCREASE-KEY( $S, i, k$ ), nicht ( $S, x, k$ )!


- Im Gegensatz zum Buch ist hier DECREASE-KEY() in einem Max-Heap gemeint.



# Die HEAP-INCREASE-KEY-Operation

```
■ HEAP-INCREASE-KEY(A, i, k)
 if(k < A[i]) error „Increase-Error“
 else
 A[i] = k
 while i > 1 and A[parent(i)] < A[i] // parent(i) entspr. hier (i div 2)
 SWAP(A[i], A[parent(i)])
 i = parent(i)
```

■ HEAP-INCREASE-KEY funktioniert wie heapify in umgekehrter Richtung:



# Die INSERT-Operation

---

- `HEAP-INSERT(A, x)`  
    `A.heap_size = A.heap_size + 1`  
    `A[A.heap_size] = -∞`  
    `HEAP-INCREASE-KEY(A, A.heap_size, x)`
  
- Mit einem Heap kann eine Priority-Queue mit Laufzeit  $O(\log N)$  für die Operationen insert, delete, increase, decrease, extract-max realisiert werden.
  
- Anmerkung:  
    Zum Auffinden eines Wertes  $x$  benötigt man eine zusätzliche Datenstruktur, z.B.
  - `HEAP-INCREASE-KEY2(A, x, k)`:  
    Problem: Finde  $i$  mit  $A[i] = x$

## 3.3 Quicksort

---

- Idee: Divide & Conquer (T. Hoare, 1960)
  - Teile die Folge in zwei Teilfolgen  $A[1...q-1]$  und  $A[q+1...n]$  mit:  
 $A[i] \leq A[q] \quad \forall i < q$  und  $A[i] \geq A[q] \quad \forall i > q$  (\*)
  - Sortiere die Teilfolgen  $A[1...q-1]$  und  $A[q+1...n]$
  - (Kombination der Teilfolgen nicht nötig aufgrund von (\*))

```
QUICKSORT(A, l, r)
```

```
 if l < r
```

```
 q = PARTITION(A, l, r) // Bestimmt q und stellt Bedingung (*) her
```

```
 QUICKSORT(A, l, q-1)
```

```
 QUICKSORT(A, q+1, r)
```

- initialer Aufruf: QUICKSORT(A, 1, A.length)

# Partition-Funktion

---

## ■ Partition-Funktion (Hoare-Zerlegung)

■ geg: ein Array  $A[l..r]$

■ ges:  $q$  mit  $l \leq q \leq r$ , umsortiertes Array  $A$  mit

$A[i] \leq A[q] \quad \forall i < q$  und  $A[i] \geq A[q] \quad \forall i > q$  //  $A[q]$ : *Pivot-Element*

```
PARTITION_HOARE(A, l, r)
// verwende A[r] als Pivot-Element
1 i = l-1; j = r;
2 while i < j
3 repeat i = i+1 until A[i] ≥ A[r]
4 repeat j = j-1 until A[j] ≤ A[r]
5 if(i < j) SWAP(A[i], A[j])
6 SWAP(A[i], A[r]) // schiebt das Pivot-Element in die Mitte
7 return i
```

# Partition-Funktion

## ■ Beispiel: Partition-Funktion nach Hoare

|          |        |   | l              |                |                |                |   |    | r              |                |
|----------|--------|---|----------------|----------------|----------------|----------------|---|----|----------------|----------------|
|          | index: |   | 1              | 2              | 3              | 4              | 5 | 6  | 7              | 8              |
|          | A      | : | 3              | 8              | 14             | 2              | 9 | 23 | 1              | 4              |
|          |        |   | ↑ <sub>i</sub> |                |                |                |   |    |                | ↑ <sub>j</sub> |
| nach 4.: | A      | : | 3              | 8              | 14             | 2              | 9 | 23 | 1              | 4              |
|          |        |   |                | ↑ <sub>i</sub> |                |                |   |    | ↑ <sub>j</sub> |                |
| nach 5.: | A      | : | 3              | 1              | 14             | 2              | 9 | 23 | 8              | 4              |
| nach 4.: |        |   |                |                | ↑ <sub>i</sub> | ↑ <sub>j</sub> |   |    |                |                |
|          |        |   |                |                |                |                |   |    |                |                |
| nach 5.: | A      | : | 3              | 1              | 2              | 14             | 9 | 23 | 8              | 4              |
| nach 4.: |        |   |                |                | ↑ <sub>j</sub> | ↑ <sub>i</sub> |   |    |                |                |
|          |        |   |                |                |                |                |   |    |                |                |
| nach 7.: | A      | : | 3              | 1              | 2              | 4              | 9 | 23 | 8              | 14             |
|          |        |   |                |                | ↑ <sub>i</sub> |                |   |    |                |                |
|          |        |   |                |                |                |                |   |    |                |                |

Pivot-Element

i und j sind übereinander  
hinweggelaufen

≤

↑<sub>i</sub>


≥

# Partition-Funktion

- Alternative Prozedur mit nur einer Schleife:

- `PARTITION(A, l, r )`

```
// verwende A[r] als Pivot-Element
i = l-1
for j = l to r-1
 if A[j] ≤ A[r]
 i = i+1
 SWAP(A[i], A[j])
SWAP(A[i+1], A[r])
return i+1
```



- Funktionsweise:

PARTITION zerlegt A in vier (ggf. leere) Bereiche:

1. für  $l \leq k \leq i$  gilt:  $A[k] \leq A[r]$
2. für  $i < k < j$  gilt:  $A[k] > A[r]$
3. für  $j \leq k < r$  gilt:  $A[k] ? A[r]$
4. für  $k = r$  gilt:  $A[k] = A[r]$

# Partition-Funktion


```

■ PARTITION(A, l, r)
 // verwende A[r] als Pivot
 i = l-1
 for j = l to r-1
 if A[j] ≤ A[r]
 i = i+1
 SWAP(A[i], A[j])
 SWAP(A[i+1], A[r])
 return i+1

```

## ■ Korrektheit: (informell)

- Fall 1:  $A[j] > A[r]$  : Verlängere Bereich 2 um ein Feld
- Fall 2:  $A[j] \leq A[r]$  : Vertausche  $A[i]$  und  $A[j]$ ,  
vergrößere Bereich 1 um ein Feld,  
verlängere Bereich 2 um ein Feld



# Analyse von Quicksort

---

- Rekurrenzgleichung für Quicksort:

- Sei  $q$  die Position des Pivot-Elements, dann gilt

$$T(N) = T(q - 1) + T(N - q) + c N$$

- Annahme: Pivot-Element ist immer das Maximum der sortierten Teilfolge, d.h.  $q = N$ :

$$T(N) = T(N-1) + T(0) + c * N = c * (N + N-1 + N-2 + \dots + 1) = \Theta(N^2)$$

- Annahme: Pivot-Element liegt in der Mitte der sortierten Teilfolge, d.h.  $q = \lceil N/2 \rceil$

$$T(N) = T(\lceil N/2 \rceil - 1) + T(N - \lceil N/2 \rceil) + c N \cong 2 T(N/2) + c N = \Theta(N \log N)$$

- Annahme: Pivot-Element liegt bei  $q = aN$  für ein konstantes  $0,5 < a < 1$


$$T(N) = T(\lceil a N \rceil) + T(\lceil (1-a)N \rceil) + c N$$

- Rekursionsbaum mit maximal  $-\log_a N = \log_{1/a} N$  Ebenen
  - Laufzeit pro Ebene des Rekursionsbaums:  $cN$
  - $T(N) = O(N \log N)$



# Analyse von Quicksort

## ■ Beispiel für $a = 0,9$ :



# Der randomisierte Quicksort

---

- **Randomisierter Algorithmus:**

Algorithmus, der unter Verwendung von Zufallszahlen operiert.

- **ACHTUNG:** Randomisierte Algorithmen sind (i.d.R.) deterministisch (d.h. sie liefern immer das gleiche Ergebnis)!

- `RAND-PARTITION(A, l, r)`

```
i = RANDOM(l, r) // wählt eine ganzzahlige Zufallszahl aus [l,r]
SWAP(A[i], A[r])
return PARTITION(A, l, r)
```

- `RAND-QUICKSORT(A, l, r)`

```
if l < r
 q = RAND-PARTITION(A, l, r)
 RAND-QUICKSORT(A, l, q-1)
 RAND-QUICKSORT(A, q+1, r)
```

- Erwartete Laufzeit von RAND-QUICKSORT ist unabhängig von der Vorsortierung

# Analyse des randomisierten Quicksort

- **Theorem:** Angenommen, alle Werte sind voneinander verschieden, dann ist die *erwartete Laufzeit* von Quicksort  $O(N \log N)$ .

- **Beweisalternative 1:** (Mittelung über die Rekurrenzgleichung)

$$T_{\text{exp}}(N) = \left[ \frac{1}{N} \sum_{q=1}^N T(q-1) + T(N-q) \right] + cN \leq \left[ \frac{2}{N} \sum_{q=1}^{\lceil N/2 \rceil} T(q) \right] + cN \stackrel{?}{=} O(N \log N)$$

- **Beweisalternative 2:** (Erwartete Anzahl Vergleiche)

- Laufzeit von Quicksort wird durch PARTITION dominiert.
- Laufzeit von PARTITION ist proportional zur Anzahl Vergleiche.
- Sei  $X$  die Anzahl Vergleiche, dann ist  $T(N, X) = O(N + X)$ .
- Wie hoch ist die erwartete Anzahl Vergleiche  $E[X]$  ?
  - Sei  $X_{ij}$  das Ereignis, dass  $A[i]$  mit  $A[j]$  verglichen wird.
  - Wenn  $X_{ij}=1$ , ist entweder  $A[i]$  oder  $A[j]$  Pivotelement, jeder Paarvergleich findet nur ein mal statt:

$$E[X] = E \left[ \sum_{i=1}^{N-1} \sum_{j=i+1}^N X_{ij} \right] = \sum_{i=1}^{N-1} \sum_{j=i+1}^N E[X_{ij}] = \sum_{i=1}^{N-1} \sum_{j=i+1}^N \Pr\{X_{ij} = 1\}$$

# Analyse des randomisierten Quicksort

- Wie hoch ist die Wahrscheinlichkeit, dass  $A[i]$  mit  $A[j]$  verglichen wird, d.h.  $\Pr\{X_{ij}=1\}$ ?

- Sei  $x$  der Pivotwert, dann gilt für alle  $A[i] < x < A[j]$ :  $\Pr\{X_{ij}=1\} = 0$
- Für jedes Teil-Array  $A[i...j]$  gilt:  $A[i]$  wird mit  $A[j]$  verglichen, genau dann wenn entweder  $A[i]$  oder  $A[j]$  als Pivotelement gewählt werden.
- $A[i...j]$  enthält  $j-i+1$  Elemente, die Wahrscheinlichkeit zur Auswahl des Pivotelements ist gleichverteilt (RAND-PARTITION):

$$\Pr\{X_{ij}=1\} = \Pr\{A[i] \text{ oder } A[j] \text{ ist erstes Pivotelement aus } A[i...j]\}$$

$$\Pr\{X_{ij}=1\} = \frac{1}{j-i+1} + \frac{1}{j-i+1} = \frac{2}{j-i+1}$$

Typo im Cormen:  
S. 156:  $k=j-i$

$$E[X] = \sum_{i=1}^{N-1} \sum_{j=i+1}^N \Pr\{X_{ij}=1\} = \sum_{i=1}^{N-1} \sum_{j=i+1}^N \frac{2}{j-i+1} \quad \text{mit } k = j-i$$

$$= \sum_{i=1}^{N-1} \sum_{k=1}^{N-i} \frac{2}{k+1} < \sum_{i=1}^{N-1} \sum_{k=1}^N \frac{2}{k} = \sum_{i=1}^{N-1} 2 \sum_{k=1}^N \frac{1}{k} \leq \sum_{i=1}^{N-1} 2(\log N + 1)$$

mit A.10  
(harmonische  
Reihe)

$$= 2(N-1)(\log N + 1) = O(N \log N)$$


# Abschließende Kommentare zu Merge-, Heap- und Quicksort

---

- **Sortieren durch Einfügen** hat eine Worst-Case Laufzeit von  $O(N^2)$ , ist allerdings vorteilhaft, wenn die Eingabe nahezu sortiert ist.
- **Mergesort** hat eine Worst-Case Laufzeit von  $O(N \log N)$ , ist aber kein in-place Sortierverfahren.
- **Mergesort** eignet sich gut für große Datenbestände auf Sekundärspeichern.
- **Heapsort** hat eine Worst-Case Laufzeit von  $O(N \log N)$  und sortiert in-place.
- Die Worst-Case Laufzeit von **Quicksort** ist  $O(N^2)$ , die erwartete Laufzeit des randomisierten Verfahrens  $O(N \log N)$ . Um eine Worst-Case Laufzeit von  $O(N \log N)$  zu erhalten, muß der Median der Eingabefolge in  $O(N)$  Zeit bestimmt werden.
- **Quicksort** zeigt in der Praxis ein sehr gutes Laufzeitverhalten (niedrige Konstanten).
- **Quicksort** kann in der Praxis weiter beschleunigt werden, in dem ein rekursiver Aufruf durch eine Iteration ersetzt wird (Endrekursion).

## 3.4 Eine untere Schranke für das Sortierproblem

- Annahme: alle zu sortierenden Elemente sind paarweise verschieden.
- Vergleichende Sortiervverfahren:
  - basieren ausschließlich auf Paarvergleiche zwischen den Elementen der Eingabe.
  - Operationen auf Elemente beschränkt auf:  $<$ ,  $\leq$ ,  $=$ ,  $\geq$ ,  $>$
  - Operationen können auf eine reduziert werden:  $\leq$
- Das Entscheidungsbaummodell:
  - vollständiger binärer Baum:
  - innere Knoten: Vergleich zwischen zwei Elementen  $A[i]$  und  $A[j]$
  - Blätter: Permutation (Rangfolge) der Elemente



# Eine untere Schranke für das Sortierproblem

---

- **Theorem:** Jedes vergleichende Sortierverfahren benötigt bei  $n$  zu sortierenden Datenelementen im Worst-Case  $\Omega(n \log n)$  Vergleichsoperationen.
  - Jedes Sortierverfahren führt eine Serie von Vergleichsoperationen aus.
  - diese entspricht einem Pfad von Wurzel zu Blatt in einem entsprechenden Entscheidungsbaum.
  - Jedes Sortierverfahren muss jede mögliche Permutation erzeugen können.
  - Der Entscheidungsbaum hat somit  $l = n!$  Blätter.
  - Die Höhe des Entscheidungsbaums ist eine untere Schranke für die Anzahl der Vergleiche:

$$h \geq \log_2 l = \log_2 n! = \Omega(N \log N)$$

|                                |
|--------------------------------|
| Gleichung 3.18<br>Cormen S. 55 |
|--------------------------------|

## 3.5 Counting-, Radix- und Bucketsort

---

- Gibt es Sortierverfahren, die nicht ‚vergleichend‘ sind?
  - Im allgemeinen nicht, da wir für die zu sortierenden Objekte lediglich die Ordnungsrelation kennen.
- **Annahme 1:** Die zu sortierenden Schlüssel sind ganzzahlig, paarweise verschieden und aus  $\{1, \dots, N\}$ 
  - `TRIVIAL_SORT(A )`  
    **for**  $i = 1$  **to**  $N$   
         $B[A[i]] = A[i]$   
    **return**  $B$
- **Annahme 2:** Die zu sortierenden Schlüssel sind ganzzahlig aus  $\{0, \dots, k\}$ ,  $k = O(N)$ 
  - Idee: Zähle die Anzahl der Elemente mit kleinerem Schlüssel.
  - ➔ Countingsort



# Countingsort

---

- Feld A: Eingabe, Feld B: sortierte Ausgabe
- Feld C[0...k]: Zähler-Array, ändert die Bedeutung während des Alg.
- COUNTING-SORT(A, B, k)

```
1 for(i = 0 to k) C[i] = 0
2 for(j = 1 to A.length) C[A[j]] ← C[A[j]] + 1
 // C[i] enthält die Anzahl der Elemente, deren Schlüssel gleich i sind
3 for(i = 1 to k) C[i] = C[i] + C[i-1]
 // C[i] enthält die Anzahl der Elemente, deren Schlüssel ≤ i sind
4 for j = A.length downto 1
5 B[C[A[j]]] = A[j]
6 C[A[j]] = C[A[j]] - 1
7 return B
```

- Laufzeit von Countingsort:  $T(N,k) = O(N + k)$   
Für  $k = O(N)$  sortiert Countingsort in Linearzeit.

# Countingsort: Ein Beispiel

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
|   | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 |
| A | 2 | 5 | 3 | 0 | 2 | 3 | 0 | 3 |

|   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|
|   | 0 | 1 | 2 | 3 | 4 | 5 |
| C | 2 | 0 | 2 | 3 | 0 | 1 |

(a)

|   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|
|   | 0 | 1 | 2 | 3 | 4 | 5 |
| C | 2 | 2 | 4 | 7 | 7 | 8 |

(b)

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
|   | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 |
| B |   |   |   |   |   |   | 3 |   |

|   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|
|   | 0 | 1 | 2 | 3 | 4 | 5 |
| C | 2 | 2 | 4 | 6 | 7 | 8 |

(c)

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
|   | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 |
| B |   | 0 |   |   |   |   | 3 |   |

|   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|
|   | 0 | 1 | 2 | 3 | 4 | 5 |
| C | 1 | 2 | 4 | 6 | 7 | 8 |

(d)

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
|   | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 |
| B |   | 0 |   |   |   | 3 | 3 |   |

|   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|
|   | 0 | 1 | 2 | 3 | 4 | 5 |
| C | 1 | 2 | 4 | 5 | 7 | 8 |

(e)

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
|   | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 |
| B | 0 | 0 | 2 | 2 | 3 | 3 | 3 | 5 |

(f)

■ Beispiel für  $N=8$ ,  $k=5$

■ a) nach Zeile 2

b) nach Zeile 3

c) nach 1. Iteration Zeile 4

■ d) nach 2. Iteration

e) nach 3. Iteration

f) nach Zeile 7

# Radixsort (Sortieren durch Fächerverteilen)

---

- **Definition:** Ein Sortierverfahren heißt *stabil*, genau dann wenn für alle  $i < j$ ,  $i, j \in \{1, \dots, N\}$  mit  $A[i] = A[j]$  gilt  $\pi(i) < \pi(j)$
- **Satz:** Countingsort ist ein stabiles Sortierverfahren.
  
- **Annahme 3:** Sortierung erfolgt nach einem  $m$ -adischen Schlüssel  $A[i] = (k_1, k_2, \dots, k_d)$ ;  $\forall 1 \leq j \leq d$ :  $k_j$  ist ganzzahlig und  $0 \leq k_j \leq m-1$
  
- Idee:
  - Verteilphase: Sortiere die Daten in  $m$  Fächer nach dem ersten (niederwertigsten!) Schlüssel
  - Sammelphase: Sammle die Daten wieder zu einer Liste
  - wiederhole mit dem nächsten Schlüssel
  - wichtig: im  $i$ -ten Durchlauf bleibt die relative Ordnung des  $i-1$ ten Durchlaufs erhalten, d.h. die Verteilphase setzt ein stabiles Sortierverfahren als Subroutine voraus

# Radixsort (Sortieren durch Fächerverteilen)

- Beispiel:  $N = 7$ ,  $m = 10$ ,  $d = 3$

|     |     |     |     |
|-----|-----|-----|-----|
| 329 | 720 | 720 | 329 |
| 457 | 355 | 329 | 355 |
| 657 | 436 | 436 | 436 |
| 839 | 457 | 839 | 457 |
| 436 | 657 | 355 | 657 |
| 720 | 329 | 457 | 720 |
| 355 | 839 | 657 | 839 |

- `RADIX-SORT(A, d, m)`  
  **for**  $j = 1$  **to**  $d$   
    // `key[j]`: Attribut, beschreibt den  $j$ -ten Schlüssel von  $A$   
    `COUNTING-SORT( key[j][A], B, m-1 )`  
     $A = B$

# Radixsort mit Warteschlangen

---

```
■ RADIXSORT(A, d, m)
 // L: array [0...m-1] von Warteschlangen
 for(j = 0 to m-1) L[j] = init()
 for t = 1 to d // sortiere nach Schlüssel t
 // Verteilphase
 for(i = 1 to N) ENQUEUE(L[key[t][A[i]]], A[i])
 // Sammelphase
 i = 1
 for j = 0 to m-1
 while not empty(L[j])
 A[i] = DEQUEUE(L[j])
 i = i+1
```

# Radixsort: Laufzeit- und Speicherbedarf

---

- Parameter

- m: Anzahl Schlüsselwerte

- d: Anzahl Schlüsselemente

- N: Anzahl der Datensätze

- Laufzeit  $T(N,d,m) = O(d(N + m))$

- Fall 1:  $d = O(1)$ ,  $m = O(N)$  :  $O(N)$

- Fall 2: Alle Schlüssel verschieden:  $d \geq \log_m N$  :  $O(N \log N)$

- Speicherbedarf:

- Implementierung mit Arrays:  $S(m,N) = O(m N)$

- Implementierung mit Schlangen :  $S(m,N) = O(m + N)$

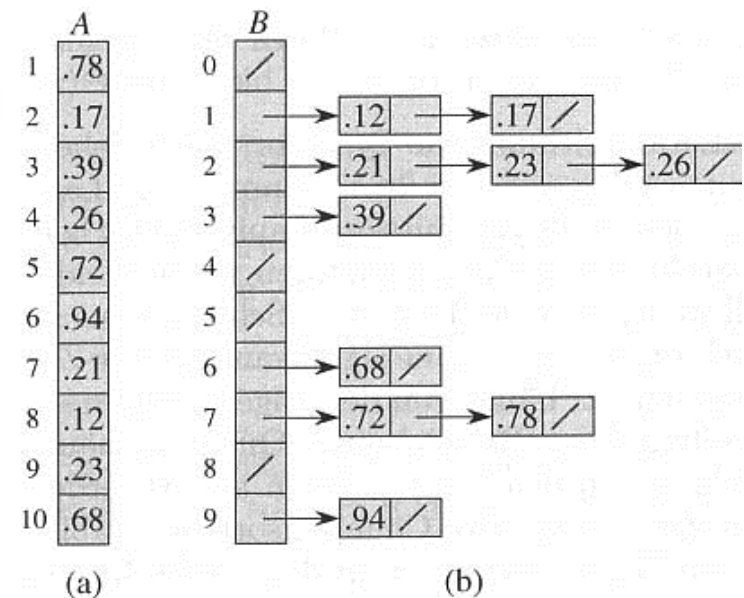
Radixsort sortiert somit nicht *in-place*.

# Bucketsort

- **Annahme 4:** Für alle Element  $A[i]$  gilt:  $A[i] \in \mathbb{R}$ ,  $0 \leq A[i] < 1$ . Die Elemente sind in  $[0,1)$  gleichverteilt.
- Idee:
  - Teile den Wertebereich in  $N$  gleich große Teilintervalle  
 $T[i] = [i/N, (i+1)/N)$ , für  $0 \leq i < N$
  - Erzeuge  $N$  Fächer  $B[0, \dots, N-1]$  mit  $N$  linearen Listen
  - Sortiere durch Fächerverteilung und verbinde die Listen

- **BUCKET-SORT( $A$ )**

```
1 for i = 1 to A.length
2 LIST-INSERT(B[⌊A.length * A[i]⌋] , A[i])
3 i = 1
4 for j = 0 to A.length-1
5 INSERTION-SORT(B[j])
6 while not EMPTY(B[j])
7 A[i] = LIST-HEAD[B[j]];
8 B[j] = LIST-TAIL[B[j]];
 i = i+1
```



# Bucketsort: Laufzeitanalyse

---

- Bucketsort ohne Zeile 5 benötigt  $O(N)$  Zeit. Sei  $n_i = \text{length}[B[i]]$ : INSERTION-SORT für Liste  $B[i]$  benötigt  $O(n_i^2)$  Zeit.
- Worst-Case:  $n_0 = N$ ,  $n_i = 0$  für alle  $i > 0$ :  $T_{\text{Bucket}}(N) = O(N^2)$   
Dieses Szenario widerspricht allerdings der Gleichverteilungsannahme.
- Worst-Case erwartete Laufzeit:

$$T_{\text{bucket}}(N) = cN + \sum_{i=0}^{N-1} cn_i^2$$

$$E[T_{\text{bucket}}(N)] = E\left[cN + \sum_{i=0}^{N-1} cn_i^2\right] = cN + \sum_{i=0}^{N-1} cE[n_i^2]$$

- Angenommen, es gilt:  $E[n_i^2] = 2 - 1/N$

$$\text{dann folgt: } E[T_{\text{bucket}}(N)] = cN + \sum_{i=0}^{N-1} c(2 - 1/N) = cN(3 - 1/N) = O(N)$$



# Bucketsort: Laufzeitanalyse

- Bleibt zu zeigen:  $E[n_i^2] = 2 - 1/N$

Sei  $X_{ij}$  das Ereignis, dass  $A[j]$  in Bucket  $i$  einsortiert wird. Dann gilt:

$$E[n_i^2] = E\left[\left(\sum_{j=1}^N X_{ij}\right)^2\right] = \sum_{j=1}^N E[X_{ij}^2] + \sum_{j=1}^N \sum_{\substack{k=1 \\ k \neq j}}^N E[X_{ij} X_{ik}]$$

(Ausmultiplizieren des Quadrats zur Trennung stochastisch abhängigen von unabhängigen Termen)

Ereignis  $X_{ij}$  tritt mit Wahrscheinlichkeit  $1/N$  auf (Gleichverteilung!):

$$E[X_{ij}^2] = 1 \frac{1}{N} + 0 \left(1 - \frac{1}{N}\right) = \frac{1}{N}$$

Ereignisse  $X_{ij}$  und  $X_{ik}$  sind unabhängig:  $E[X_{ij} X_{ik}] = E[X_{ij}] E[X_{ik}] = \frac{1}{N^2}$

Insgesamt folgt:  $E[n_i^2] = \sum_{j=1}^N \frac{1}{N} + \sum_{j=1}^N \sum_{\substack{k=1 \\ k \neq j}}^N \frac{1}{N^2} = N \frac{1}{N} + N(N-1) \frac{1}{N^2} = 2 - \frac{1}{N}$

# Bucketsort: Laufzeitanalyse

- Alternative Herleitung für:  $E[n_i^2] = 2 - 1/N$

Bestimmung über die Varianz:  $E[n_i^2] = V[n_i] + E^2[n_i]$

(dadurch entfällt die explizite Berechnung des Funktionsquadrats)

Im folgenden laufen alle Summen ohne expl. Indizes von  $j=1, \dots, N$ .

Es gilt:

$$E[n_i] = E\left[\sum X_{ij}\right] = \sum E[X_{ij}] = \sum \frac{1}{N} = 1$$

$$\begin{aligned} V[X_{ij}] &= \sum_{z=0}^1 \Pr\{X_{ij} = z\} (z - E[X_{ij}])^2 \\ &= \underbrace{\left(1 - \frac{1}{N}\right) \left(0 - \frac{1}{N}\right)^2}_{z=0} + \underbrace{\left(\frac{1}{N}\right) \left(1 - \frac{1}{N}\right)^2}_{z=1} = \left(1 - \frac{1}{N}\right) \left(\left(\frac{1}{N}\right)^2 + \frac{1}{N} - \left(\frac{1}{N}\right)^2\right) = \frac{1}{N} - \frac{1}{N^2} \end{aligned}$$

$$V[n_i] = V\left[\sum X_{ij}\right] = \sum V[X_{ij}] = \sum \left(\frac{1}{N} - \frac{1}{N^2}\right) = 1 - \frac{1}{N}$$

$$E[n_i^2] = V[n_i] + E^2[n_i] = 1 - \frac{1}{N} + 1^2 = 2 - \frac{1}{N}$$

Achtung: Die Umformung setzt stochastische Unabhängigkeit der  $X_{ij}$  voraus.

# Abschließende Kommentare zu Sortieren in Linearzeit

---

- Wenn wir nur die Vergleichsrelation für die Sortierung von Objekten zur Verfügung haben, gilt die **untere Laufzeitschranke**  $\Omega(N \log N)$ .
- Wenn arithmetische Operationen auf Schlüsseln möglich sind, kann diese Schranke unter Umständen durchbrochen werden:
  - Annahme 1: Die zu sortierenden Schlüssel sind ganzzahlig, paarweise verschieden und aus  $\{1, \dots, N\}$  → **Trivialsort**
  - Annahme 2: Die zu sortierenden Schlüssel sind ganzzahlig aus  $\{0, \dots, k\}$ ,  $k = O(N)$  → **Countingsort**
  - Annahme 3: Sortierung erfolgt nach einem  $m$ -adischen Schlüssel  $A[i] = (k_1, k_2, \dots, k_d)$ ;  $\forall 1 \leq j \leq d$ :  $k_j$  ist ganzzahlig und  $0 \leq k_j \leq m-1$  → **Radixsort**
  - Annahme 4: Für alle Element  $A[i]$  gilt:  $A[i] \in \mathbb{R}$ ,  $0 \leq A[i] < 1$ . Die Elemente sind in  $[0, 1)$  gleichverteilt. → **Bucketsort**
  - **Bucketsort** kann auch verwendet werden, wenn wir die Verteilung der Elemente kennen und eine Funktion entwickeln können, die die Elemente auf  $[0, \dots, N-1]$  gleichverteilt.

## 3.6 Algorithmen für Auswahlprobleme

---

### ■ Suchproblem:

- Eingabe eine sortierte Folge  $A$  mit  $N$  Schlüsseln  $A[i]$  und einen Suchschlüssel  $q$
- Ausgabe: Index eines Elements  $k$  mit  $A[k] = q$  oder  $-1$ , falls  $A[k] \neq q$  für alle  $k$

### ■ Auswahlproblem:

- Eingabe: Eine Menge  $A$  aus  $N$  (paarweise verschiedenen) Zahlen und einen Suchindex  $i$  mit  $1 \leq i \leq N$
- Ausgabe: Das Element  $x \in A$  mit  $A[k] < x$  für  $i-1$  Elemente  $A[k]$

# Suchen in sortierten Folgen

---

## ■ Algorithmus 1: Lineare Suche

■ `LINEAR-SEARCH(A, q )`

```
for(i = 1 to A.length) if(A[i] == q) return i
return -1
```

■ Laufzeit:  $O(k)$ , falls  $q$  in der Folge vorkommt,  $O(N)$  sonst

## ■ Algorithmus 2: Binäre Suche (Aufruf mit `BINARY-SEARCH(A,1,length[A],q)`)

■ `BINARY-SEARCH(A, l, r, q)`

```
if(l > r) return -1
```

```
else
```

```
 m ← ⌊(l+r)/2⌋
```

```
 if(A[m] > q) BINARY-SEARCH(A, l, m-1, q)
```

```
 elseif(A[m] < q) BINARY-SEARCH(A, m+1, r, q)
```

```
 else return m
```

■ Laufzeit:  $T(N) = T(N/2) + c = O(\log N)$

# Suchen in sortierten Folgen

---

## ■ Algorithmus 3: Exponentielle Suche

- Idee: Verdopple den rechten Rand bis  $A[r] > q$  gilt, führe binäre Suche im Intervall  $[r/2, \dots, r]$  durch

## ■ EXPONENTIAL-SEARCH( $A, q$ )

1  $r \leftarrow 1$

2 **while**(  $A[r] < q$  **and**  $r < N$  )  $r = \min( 2r, N )$

3 **return** BINARY-SEARCH( $A, r/2+1, r, q$ )

## ■ Laufzeit:

◆ Fall 1:  $\exists k : A[k] = q$

Schleife 2:  $\log_2 k + 1$  Durchläufe, dann gilt  $r/2 < k \leq r$   $O(\log k)$

Binäre Suche:  $O(\log r/2) = O(\log r - 1) =$   $O(\log k)$

Gesamtzeit:  $O(\log k)$

◆ Fall 2:  $\forall k : A[k] \neq q$   $O(\log N)$

Die Laufzeit von EXPONENTIAL-SEARCH ist **output-sensitiv**, d.h. sie hängt vom Resultat der Suche ab.

# Das Auswahlproblem

---

## ■ Auswahlproblem:

■ Eingabe: Eine Menge  $A$  aus  $N$  (paarweise verschiedenen) Zahlen und einen Suchindex  $i$  mit  $1 \leq i \leq N$

■ Ausgabe: Das Element  $x \in A$  mit  $A[k] < x$  für  $i-1$  Elemente  $A[k]$

## ■ Bsp:

■  $i=1$ : Minimum-Problem  $O(N)$

■  $i=N$ : Maximum-Problem  $O(N)$

■  $i=N/2$ : Median-Problem ?

## ■ Algorithmus 1: Iteratives Löschen der Minima

```
TRIVIAL-SELECT(A, i)
```

```
 $n \leftarrow \text{length}[A]$
```

```
while $i > 0$
```

```
 $k = \text{MIN-INDEX}(A, n)$ // gibt den Index des min. Elements aus $A[1\dots n]$
```

```
 SWAP($A[k], A[n]$)
```

```
 $i = i-1; n = n-1;$
```

```
return $A[n+1]$
```

Laufzeit:  $T(N,i) = \Theta(i N) = O(N^2)$

# Der QUICK-SELECT Algorithmus

---

## ■ Algorithmus 2: Sortieren

`SORT-SELECT(A, i)`

`HEAPSORT(A)`

**output** `A[i]`

Laufzeit:  $O(N \log N)$

## ■ Algorithmus 3: Partielle Sortierung mit Quicksort

`RAND-SELECT( A, l, r, i )`

1 **if**( `l == r` ) **return** `A[l]`      // Annahme:  $l \leq i \leq r$

2 **else**

3    `q = RAND-PARTITION(A, l, r)`

4    **if**( `i == q` ) **return** `A[q]`

5    **elseif**( `i < q` ) `RAND-SELECT(A, l, q-1, i )`

6    **else** `RAND-SELECT(A, q+1, r, i)`

Achtung: `RAND-SELECT()` und `RANDOMIZED-SELECT()` [Cormen Kap. 9.2] weichen geringfügig voneinander ab, lösen aber das gleiche Problem.



# Der RAND-SELECT Algorithmus

■ Beispiel:  $N=8$ ,  $i=6$

index: 1 2 3 4 5 6 7 8

A: 3 8 14 2 9 23 1 6 ← Pivot-Element

nach 3.:

A: 3 1 2 6 9 23 8 14  
 $\boxed{\leq}$   $\uparrow q$   $\boxed{\geq}$

A: x x x x 9 23 8 14

nach 3.:

A: x x x x 9 8 14 23  
 $\boxed{\leq}$   $\uparrow q$   $\boxed{\geq}$

A: x x x x 9 8 x x

nach 3.:

A: x x x x 8 9 x x  
 $\uparrow q$   $\boxed{\geq}$

A: x x x x x 9 x x  
 $\uparrow l=r=i$

# Analyse des RAND-SELECT Algorithmus

---

- Rekurrenzgleichung für Rand-Select:

- Sei  $q$  die Position des Pivot-Elements, dann gilt

$$T(N) = T(q - 1) + aN \text{ falls } i < q, \quad T(N) = T(N - q) + aN \text{ sonst.}$$

- Worst-Case:  $q=N \Rightarrow T(N) = T(N-1) + aN = \Theta(N^2)$

- Wie hoch ist die erwartete Laufzeit  $E[T(N)]$  für Rand-Select?

- Alle Elemente  $A[k]$  können gleichwahrscheinlich als Pivot-Element gewählt werden.
  - Im Worst-Case liegt der gesuchte Rang  $i$  immer in der größeren Partition

$$\begin{aligned} E[T(N)] &\leq \sum_{k=1}^N \Pr\{q = k\} E[T(\max(k-1, N-k) + aN)] \\ &= \sum_{k=1}^N \frac{1}{N} E[T(\max(k-1, N-k) + aN)] = \frac{1}{N} \sum_{k=1}^N E[T(\max(k-1, N-k))] + aN \end{aligned}$$

# Analyse des RAND-SELECT Algorithmus

---

- Wie hoch ist die erwartete Laufzeit  $E[T(N)]$  für Rand-Select?

- Für  $k < N/2$  ergibt sich für  $k$  und  $N-k+1$  der gleiche Summand:

$$\max(k-1, N-k) = N-k = \max((N-k+1)-1, N-(N-k+1))$$

$$E[T(N)] \leq \frac{1}{N} \sum_{k=1}^N E[T(\max(k-1, N-k))] + aN \leq \frac{2}{N} \sum_{k=\lfloor N/2 \rfloor}^{N-1} E[T(k)] + aN$$

- Welche Laufzeitschranke sollten wir intuitiv erwarten?
  - Im Vergleich zu Quicksort erfolgt nur ein rekursiver Aufruf, also höchstens  $O(N \log N)$
  - Angenommen,  $k=N/2$ , dann folgt  $T(N)=T(N/2)+ cN = O(N)$

# Analyse des Rand-SELECT Algorithmus

- Annahme:  $E[T[N]] = O(N)$ , d.h.  $E[T[N]] \leq c N$  für ein konstantes  $c$

- Beweis:

$$\begin{aligned} E[T(N)] &\leq \frac{2}{N} \sum_{k=\lfloor N/2 \rfloor}^{N-1} ck + aN \\ &= \frac{2c}{N} \sum_{k=0}^{\lceil N/2 \rceil - 1} (\lfloor N/2 \rfloor + k) + aN \\ &= \frac{2c(\lceil N/2 \rceil)\lfloor N/2 \rfloor}{N} + \frac{2c(\lceil N/2 \rceil - 1)(\lceil N/2 \rceil)}{N} + aN \\ &\leq \frac{2c(N/2 + 1)(N/2)}{N} + \frac{2c(N/2)(N/2 + 1)}{N} + aN \\ &= \frac{cN}{2} + c + \frac{cN}{4} + \frac{c}{2} + aN = \frac{3cN}{4} + \frac{3c}{2} + aN \\ &= cN - \left( \frac{cN}{4} - \frac{3c}{2} - aN \right) \leq cN \quad \text{für } N \geq \frac{6c}{c - 4a} \end{aligned}$$

# Analyse des Rand-SELECT Algorithmus (Cormen-Variante)

---

$$\begin{aligned} E[T(N)] &\leq \frac{2}{N} \sum_{k=\lfloor N/2 \rfloor}^{N-1} ck + aN \\ &= \frac{2c}{N} \left( \sum_{k=1}^{N-1} k - \sum_{k=1}^{\lfloor N/2 \rfloor - 1} k \right) + aN \\ &= \frac{2c}{N} \left( \frac{(N-1)N}{2} - \frac{(\lfloor N/2 \rfloor - 1)\lfloor N/2 \rfloor}{2} \right) + aN \\ &\leq \frac{2c}{N} \left( \frac{(N-1)N}{2} - \frac{(N/2 - 2)(N/2 - 1)}{2} \right) + aN \\ &= \frac{2c}{N} \left( \frac{3N^2}{4} + \frac{N}{2} - 2 \right) + aN = \frac{3cN}{4} + \frac{c}{2} + aN \\ &= cN - \left( \frac{cN}{4} - \frac{c}{2} - aN \right) \leq cN \quad \text{für } N \geq \frac{2c}{c - 4a} \end{aligned}$$

# Der SELECT-Algorithmus


---

- Gibt es einen deterministischen Algorithmus für das Auswahlproblem mit asymptotisch linearer Laufzeit im Worst-Case?
- Idee: Verwende Rand-Select und garantiere, dass die Position  $q$  des Pivotelement nahe bei  $N/2$  liegt.

```
■ SELECT(A, l, r, i)
 1 if(l = r) return A[l] // Annahme: $l \leq i \leq r$
 2 else
 3 $q = \text{FIND-PIVOT-POSITION}(A, l, r)$
 4 $\text{SWAP}(A[q], A[r])$
 5 $q = \text{PARTITION}(A, l, r)$
 6 if(i == q) return A[q]
 7 elseif(i < q) SELECT(A, l, q-1, i)
 8 else SELECT(A, q+1, r, i)
```

# Der SELECT-Algorithmus

- Idee: Teile Menge in Fünfer-Gruppen, berechne die Fünfer-Mediane und den Median der Fünfer-Mediane:




- `FIND-PIVOT-POSITION(A, l, r)`  
`n = r-l+1`  
`// berechne die Mediane von je 5 benachbarten Elementen`  
**for** `i = 1 to ⌈n/5⌉`  
    `INSERTION-SORT( A[ (l + 5(i-1)), ..., min( l+5i, r ) ] )`  
    `M[i] = A[ min( l + 5i - 3, r ) ]`  
`// berechne rekursiv den Median der Mediane-von-5`  
`x = SELECT( M, 1, ⌈n/5⌉, ⌊ ⌈n/5⌉/2 ⌋ )`  
**return** `( min( l + 5 x - 3, r ) )`

# Die Analyse des SELECT-Algorithmus

- FIND-PIVOT-POSITION: Wie viele Elemente aus  $A[l, \dots, r]$  sind größer als  $A[x]$ ?
  - die Hälfte der Fünfer-Mediane  
+ je zwei weitere Elemente  
- ohne die letzte Gruppe und  
- ohne die Gruppe, die  $x$  enthält

$$3 \left( \left\lceil \frac{1}{2} \left\lceil \frac{N}{5} \right\rceil \right\rceil - 2 \right) \geq \frac{3N}{10} - 6 = G(N)$$

- Der rekursive Aufruf von SELECT (Zeile 7 oder 8) erfolgt mit maximal  $7N/10 + 6$  Elementen.

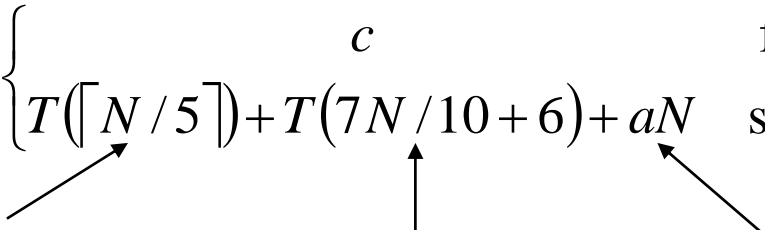




# Die Analyse des SELECT-Algorithmus

## ■ Die Rekurrenz-Gleichung für SELECT:

$$T(N) = \begin{cases} c & \text{falls } n \leq 70 \\ T(\lceil N/5 \rceil) + T(7N/10 + 6) + aN & \text{sonst} \end{cases}$$



SELECT-Aufruf in FIND-PIVOT-POSITION      SELECT-Aufruf in SELECT      - Bestimmung der Fünfer-Mediane  
- Aufruf von PARTITION

■ Annahme:  $T(N) = O(N)$ , d.h.  $T(N) \leq cN$  für ein konstantes  $c$

■ Beweis: Für alle  $N \leq 70$  ist  $T(N) = c$  konstant. Sei  $N > 70$ , dann gilt:

$$\begin{aligned} T(N) &\leq c \left\lceil \frac{N}{5} \right\rceil + c \left( \frac{7N}{10} + 6 \right) + aN \\ &\leq \frac{cN}{5} + c + \frac{7cN}{10} + 6c + aN = \frac{9cN}{10} + 7c + aN \\ &= cN - \left( \frac{1}{10}cN - 7c - aN \right) \leq cN \\ &\Leftrightarrow \frac{1}{10}cN - 7c - aN \geq 0 \Leftrightarrow c \geq 10a \left( \frac{N}{N-70} \right) \text{ für } N > 70 \end{aligned}$$

# Abschließende Bemerkungen zum Auswahlproblem

---

- Das Auswahlproblem kann in asymptotisch erwarteter linearer Zeit mit dem **RAND-SELECT-Algorithmus** gelöst werden.
- Es gibt einen deterministischen Algorithmus (**SELECT-Algorithmus**), der das Auswahlproblem im Worst Case in asymptotisch linearer Zeit löst.
- Der **SELECT-Algorithmus** ist aufgrund hoher Konstanten nur von Interesse, falls die Eingaben sehr groß sind und eine Laufzeitgarantie gefordert ist.
- Lehren für die Algorithmenentwicklung:
  - Ein randomisierter, rekursiver Algorithmus, der in asymptotisch linearer Zeit die Eingabe gleichverteilt um einen Faktor  $\alpha \in [0,1)$  verkleinert, hat asymptotisch eine erwartete lineare Laufzeit.
  - Ein deterministischer, rekursiver Algorithmus, der in asymptotisch linearer Zeit die Eingabe um einen Faktor  $\alpha \in [0,1)$  verkleinert, hat asymptotisch eine lineare Laufzeit.