

Kapitel 4: Suchen

1. Suchbäume
2. Rot-Schwarz-Bäume
3. AVL-Bäume
4. Hashing mit Verkettung
5. Hashing mit offener Adressierung

4.1 Suchbäume

- Datenstrukturen für **Wörterbücher**:
 - dynamische Datenstruktur: Objekte können eingefügt (INSERT-Operation) und gelöscht (DELETE-Operation)
 - Objekte besitzen einen Schlüssel $key[]$, für den die totale Ordnungsrelation \leq definiert ist.
 - Die Datenstruktur erlaubt den geordneten Zugriff auf Objekte:
 - ◆ $SEARCH(T,x)$: Objekt mit dem Schlüssel x
 - ◆ $MINIMUM(T)$ / $MAXIMUM(T)$: Objekt mit kleinstem/größtem Schlüssel
 - ◆ $PREDECESSOR(T,x)$ / $SUCCESSOR(T,x)$: Objekt mit nächst kleinerem/größerem Schlüssel
- **Ziel:** Entwicklung einer Datenstruktur mit asymptotischer Worst-Case Laufzeit $O(\log N)$ für alle Operationen bei Speicherung von N Objekten.

Suchbäume

■ Binärer Suchbaum:

Geordneter Baum T mit ausgezeichneteter Wurzel $T.root$, die Knoten x haben die Attribute:


- $x.key$: Schlüssel des gespeicherten Objekts
- $x.left$: linker Kind-Knoten von x
- $x.right$: rechter Kind-Knoten von x
- $x.p$: Elter-Knoten von x

■ Binäre Suchbaumeigenschaft:

Für jeden Knoten x gilt:

Sei y ein Knoten im linken Teilbaum von x , dann gilt $y.key < x.key$.

Sei y ein Knoten im rechten Teilbaum von x , dann gilt $y.key \geq x.key$.




Traversieren von Bäumen

- **Traversierung:** Systematisches Durchlaufen aller Knoten eines Baumes
- Mögliche Reihenfolgen:
 - **Preorder:** Wurzel, linker Teilbaum, rechter Teilbaum
 - **Postorder:** linker Teilbaum, rechter Teilbaum, Wurzel
 - **Inorder:** linker Teilbaum, Wurzel, rechter Teilbaum

- **INORDER-TREE-WALK(x)**

```
// Aufruf mit INORDER-TREE-WALK( T.root )
```

```
if x ≠ NIL  
    INORDER-TREE-WALK( x.left )  
    print x.key  
    INORDER-TREE-WALK( x.right )
```



Inorder: 1, 3, 14, 15, 17, 27, 39

Traversierung von Bäumen

- **Theorem 1:** Erfüllt ein Baum T die binäre Suchbaumeigenschaft, dann gibt die Funktion `INORDER-TREE-WALK()` die Objekte nach aufsteigenden Schlüsselwerten aus.
- Beweis: Für jedes Objektpaar x, y mit $x.key \leq y.key$ gilt: Sei p der kleinste gemeinsame Vorfahr von x und y .
 - Fall 1: $x=p$ y befindet sich im rechten Teilbaum.
 - Fall 2: $y=p$ x befindet sich im linken Teilbaum.
 - Fall 3: $x \neq p \neq y$ x befindet sich im linken, y im rechten Teilbaum.
- **Theorem 2:** `INORDER-TREE-WALK()` benötigt auf einem Baum mit N Knoten die Laufzeit $O(N)$
- Beweis: Sei k die Größe des linken Teilbaums. Es gilt die Rekurrenzgleichung:

$$T(N) = \begin{cases} c & : N \leq 1 \\ T(k) + T(N - k - 1) + d & : \text{sonst} \end{cases}$$

Es gilt $T(N) = (c + d)N + c = O(N)$. (Beweis durch Induktion)

Suchen in Suchbäume


■ TREE-SEARCH(x, k)

```
if(  $x == \text{NIL}$  or  $k == x.\text{key}$  ) return  $x$ 
elseif(  $k < \text{key}[x]$  ) return TREE-SEARCH( $x.\text{left}, k$ )
else return TREE-SEARCH( $x.\text{right}, k$ )
```

■ ITERATIVE-TREE-SEARCH(x, k)

```
while(  $x \neq \text{NIL}$  and  $k \neq x.\text{key}$  )
    if(  $k < \text{key}[x]$  )  $x = x.\text{left}$ 
    else  $x = x.\text{right}$ 
return  $x$ 
```

■ Bsp: TREE-SEARCH($\text{root}[T], 17$):

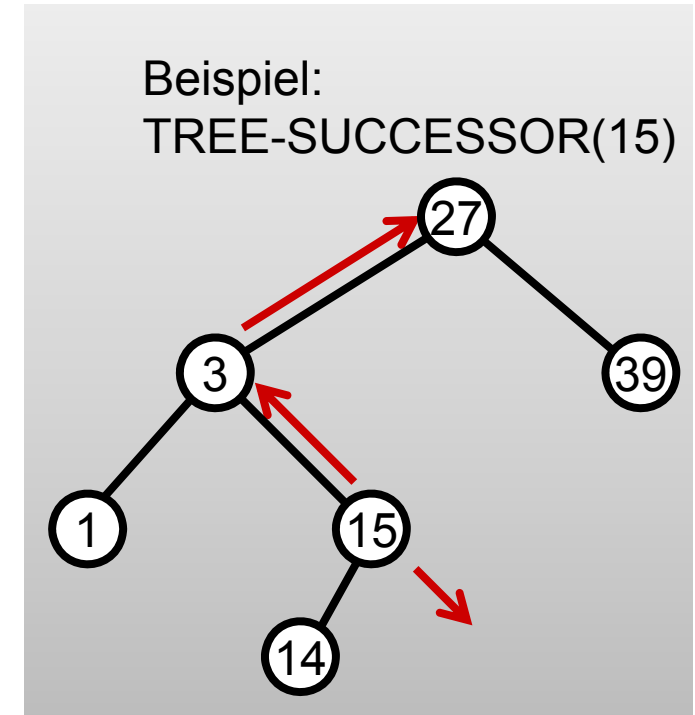


■ Theorem 3: Sei h die Höhe des Suchbaum T , dann hat TREE-SEARCH($\text{root}[T], k$) Laufzeit $O(h)$.

■ Beweis: TREE-SEARCH durchläuft einen Pfad von der Wurzel bis zu einem Blatt mit konstanter Laufzeit pro besuchten Knoten.

Minimum- und Successor-Funktion

- `TREE-MINIMUM(x)`
// Aufruf mit `TREE-MINIMUM(root[T])`
`while(x.left \neq NIL) x = x.left`
`return x`
- `TREE-SUCCESSOR(x)`
// finde Knoten y mit `key[y] > key[x]`, `key[y]` minimal
`if(x.right \neq NIL)`
 `return TREE-MINIMUM(x.right)`
`else`
 `y = x.p`
 `while(y \neq NIL and x == y.right)`
 `x = y; y = p[y]`
`return y`



- **Theorem 4:** Sei h die Höhe des Suchbaum T , dann hat `TREE-MINIMUM(root[T])` Laufzeit $O(h)$; `TREE-SUCCESSOR()` für jeden Knoten x des Suchbaums Worst-Case Laufzeit $O(h)$.
 - Beweis: Für jeden Knoten x durchläuft `TREE-SUCCESSOR` entweder den Pfad von x zu einem Blatt oder zur Wurzel.

Korrektheit von TREE-SUCCESSOR()


- **Theorem 5:** TREE-SUCCESSOR(x) bestimmt Knoten y mit den Eigenschaften $y.\text{key} \geq x.\text{key}$ und $y.\text{key}$ minimal.
- Beweis: Sei $k.T$ der Teilbaum unter Knoten k . Sei $x = p_0, p_1, \dots, p_l = T.\text{root}$ der Pfad von x zur Wurzel.
 - **Fall 1:** x hat einen rechten Nachfolger: Sei $y \in x.\text{right}.T$ mit $y.\text{key}$ minimal. $\forall i \in \{1, \dots, l\}$ gilt:

Fall 1.a: $p_{i-1} = p_i.\text{right}$:

$\forall k \in p_i.\text{left}.T: k.\text{key} \leq p_i.\text{key} \leq x.\text{key}$

Fall 1.b: $p_{i-1} = p_i.\text{left}$:

$\forall k \in p_i.\text{right}.T: k.\text{key} \geq p_i.\text{key} \geq y.\text{key}$



Korrektheit von TREE-SUCCESSOR()

- **Fall 2:** x hat keinen rechten Nachfolger.
Sei $y = p_j$ mit $p_{j-1} = p_j.\text{left}$, j minimal.

Fall 2.a: $\forall i \in \{1, \dots, j-1\}$:

$$\forall k \in p_i.\text{left}.T: k.\text{key} \leq p_i.\text{key} \leq x.\text{key}$$

Fall 2.b: $\forall i \in \{j+1, \dots, l\}$ mit $p_{i-1} = p_i.\text{right}$:

$$\forall k \in p_i.\text{left}.T: k.\text{key} \leq p_i.\text{key} \leq x.\text{key}$$


Fall 2.c: $\forall i \in \{j+1, \dots, l\}$ mit $p_{i-1} = p_i.\text{left}$:

$$\forall k \in p_i.\text{right}.T: k.\text{key} \geq p_i.\text{key} \geq y.\text{key}$$

Desweiteren gilt

$$\forall k \in p_j.\text{right}.T: k.\text{key} \geq p_j.\text{key} \geq y.\text{key}$$

Da TREE-SUCCESSOR() y gemäß Fall 1 oder 2 berechnet, folgt das Theorem.




Einfügen in Suchbäume


- Idee: laufe unter Berücksichtigung der Suchbaumeigenschaft von der Wurzel zu einem Blatt, hänge das neue Objekt an.

- `TREE-INSERT(T, z)`

```
x = T.root
y = NIL    // speichert x.p
while( x ≠ NIL )
    y = x
    if( z.key < x.key ) x = x.left
    else x = x.right
p[z] = y
if( y == NIL ) root[T] = z
elseif( z.key < y.key ) y.left = z
else y.right = z
```



↓ `TREE-INSERT()` mit
`z.key = 13`



Einfügen in Suchbäume

- `REC-TREE-INSERT(x, z)`

// Aufruf mit `REC-TREE-INSERT(root[T], z)` für nicht-leere Bäume


```
if( z.key < x.key )  
    if( x.left ≠ NIL ) REC-TREE-INSERT(x.left, z)  
    else z.p = x; x.left = z  
else  
    if( x.right ≠ NIL ) REC-TREE-INSERT(x.right, z)  
    else z.p = x; x.right = z
```

- **Theorem 6:** Sei h die Höhe des Suchbaum T , dann hat `TREE-INSERT(T , z)` und `REC-TREE-INSERT(T .root, z)` die asymptotische Worst-Case Laufzeit $O(h)$.

Löschen aus Suchbäumen

■ Löschen eines Knotens z unter Erhalt der Suchbaum-Eigenschaft:

- Fall 1: z ist ein Blatt: Lösche z
- Fall 2: z hat nur einen Nachfolger x: x wird Nachfolger von z.p
- Fall 3: z hat zwei Nachfolger: Ersetze z durch TREE-SUCCESSOR(z)



Löschen aus Suchbäumen


```
■ TREE-DELETE-NODE(T, z) // Cormen: TREE-DELETE()
// y: der (nach Tausch) zu löschende Knoten
1 if( z.left == NIL or z.right == NIL ) y = z
2 else y = TREE-MINIMUM( z.right ) // Cormen: TREE-SUCCESSOR(z)
// x: Kind von y, das nicht NIL ist
3 if( y.left != NIL ) x = y.left
  else x = y.right
// entferne y aus der Baumstruktur
4 if( x != NIL ) x.p = y.p
5 if( y.p == NIL ) T.root = x
6 else
    if( y == y.p.left ) y.p.left = x
    else y.p.right = x
// kopiere Daten von y nach z
8 if( y != z ) z.key = y.key
9 delete y

■ TREE-DELETE(T, k )
TREE-DELETE-NODE( T, TREE-SEARCH(T.root, k) )
```

Löschen aus Suchbäumen

```
■ TREE-DELETE-NODE(T, z)
  // y: der (nach Tausch) zu löschende Knoten
  1 if( z.left == NIL or z.right == NIL )
    y = z
  2 else y = TREE-MINIMUM( z.right )
  // x: Kind von y, das nicht NIL ist
  3 if( y.left ≠ NIL ) x = y.left
    else x = y.right
  // entferne y aus der Baumstruktur
  4 if( x ≠ NIL ) x.p = y.p
  5 if( y.p == NIL ) T.root = x
  6 else
    if( y == y.p.left ) y.p.left = x
    else y.p.right = x
  // kopiere Daten von y nach z
  8 if( y ≠ z ) z.key = y.key
  9 delete y
```

Fall 1:




x = NIL

Löschen aus Suchbäumen


```
■ TREE-DELETE-NODE(T, z)
  // y: der (nach Tausch) zu löschende Knoten
  1 if( z.left == NIL or z.right == NIL )
    y = z
  2 else y = TREE-MINIMUM( z.right )
  // x: Kind von y, das nicht NIL ist
  3 if( y.left != NIL ) x = y.left
    else x = y.right
  // entferne y aus der Baumstruktur
  4 if( x != NIL ) x.p = y.p
  5 if( y.p == NIL ) T.root = x
  6 else
    if( y == y.p.left ) y.p.left = x
    else y.p.right = x
  // kopiere Daten von y nach z
  8 if( y != z ) z.key = y.key
  9 delete y
```

Fall 2:



Löschen aus Suchbäumen

```
■ TREE-DELETE-NODE(T, z)
  // y: der (nach Tausch) zu löschende Knoten
  1 if( z.left == NIL or z.right == NIL )
    y = z
  2 else y = TREE-MINIMUM( z.right )
  // x: Kind von y, das nicht NIL ist
  3 if( y.left != NIL ) x = y.left
    else x = y.right
  // entferne y aus der Baumstruktur
  4 if( x != NIL ) x.p = y.p
  5 if( y.p == NIL ) T.root = x
  6 else
    if( y == y.p.left ) y.p.left = x
    else y.p.right = x
  // kopiere Daten von y nach z
  8 if( y != z ) z.key = y.key
  9 delete y
```




Suchbäume

- **Theorem 7:** Sei h die Höhe des Suchbaum T , dann hat TREE-DELETE(T, k) die asymptotische Worst-Case Laufzeit $O(h)$.
 - TREE-SEARCH durchläuft einen Pfad von der Wurzel zum zu löschenden Knoten z .
 - TREE-DELETE-NODE durchläuft einen Pfad vom zu löschenden Knoten z zu einem Blatt.
- Alle Wörterbuch-Operationen können im Suchbaum in Laufzeit $O(h)$ realisiert werden.
- Definition: Ein Suchbaum T mit Höhe $h(T)$ heißt **balanciert**, g.d.w. $h(T) = O(\log |T|)$ gilt.

■ Welche Höhe hat ein Suchbaum?

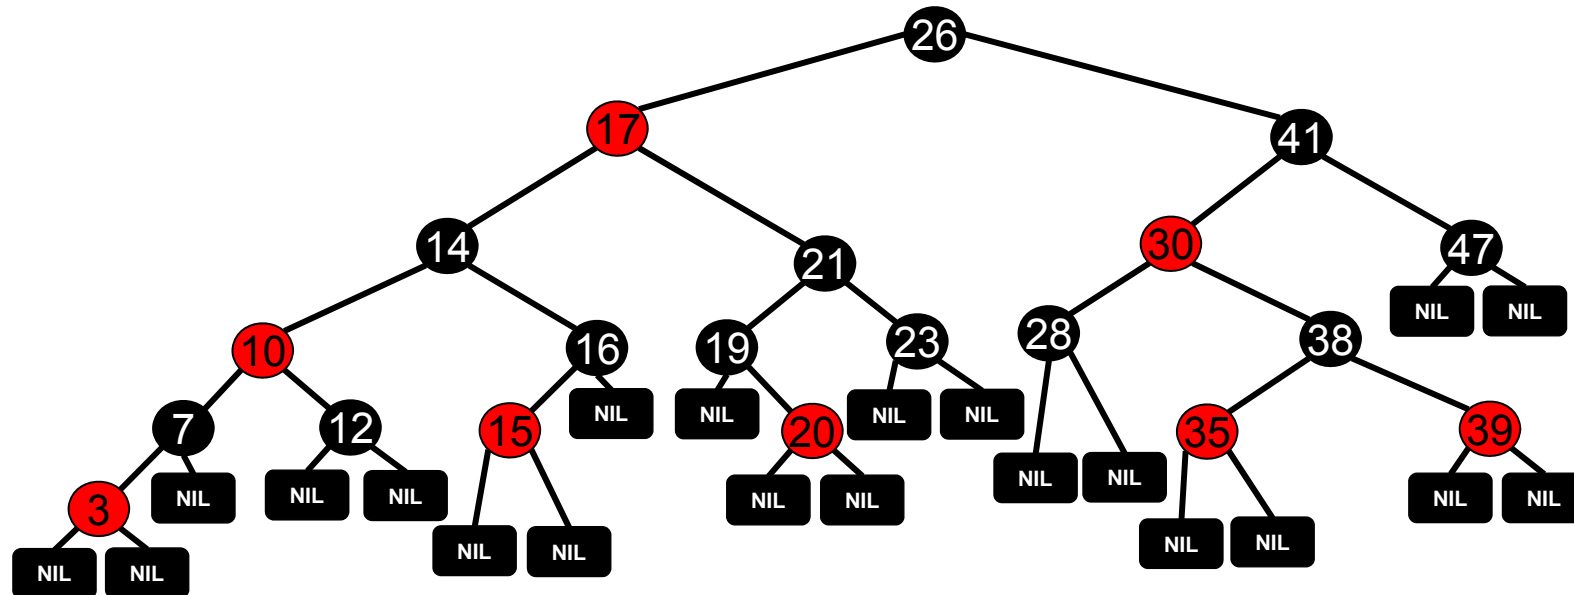
■ Best Case	Zufällig erzeugter Binärbaum	Worst Case
$O(\log N)$	$O(\log N)$	$\Omega(N)$

4.2 Rot-Schwarz-Bäume



- **Rot-Schwarz-Bäume:** Suchbäume mit den Knoten-Attributen:
 - $x.p$: Vorgänger
 - $x.left, x.right$: linker und rechter Nachfolger
 - $x.key$: Schlüsselement
 - $x.color$: Farbe (rot oder schwarz)
 - $color$ erfüllt die *Rot-Schwarz-Eigenschaften*
- Blätter werden durch den Wächter $NIL = T.nil$ repräsentiert
- Definition: Sei $T(x)$ der Teilbaum unter x , $h(T)$ die Höhe eines Baumes

Rot-Schwarz-Bäume



■ Rot-Schwarz-Eigenschaften:

1. Jeder Knoten ist entweder rot oder schwarz.
2. Die Wurzel ist schwarz.
3. Jedes Blatt (der Wächter) ist schwarz.
4. Für jeden roten Knoten gilt: beide Nachfolger sind schwarz.
5. Für jeden Knoten x gilt: Alle Pfade von x zu einem Blatt enthalten die gleiche Anzahl $bh(x)$ schwarzer Knoten.

■ Definition: $bh(x)$: Schwarz-Höhe des Knotens x

Höhe von Rot-Schwarz-Bäumen

■ **Lemma:** Ein Rot-Schwarz-Baum T mit N inneren Knoten hat höchstens die Höhe $2\log_2(N+1)$.

■ **Beweis:**

■ **Teil 1:** Zeige $\forall x : |T(x)| \geq 2^{bh(x)} - 1$ durch Induktion über $h(T(x))$
Für x mit $h(T(x))=0$ gilt: $bh(x)=0$, $1 = |T(x)| \geq 2^0 - 1 = 0$

Sei x ein Knoten mit $h(T(x)) > 0$:

◆ **Fall 1:** $x.color = \text{rot}$

$\Rightarrow x.left.color = x.right.color = \text{schwarz}$ und somit

$bh(x.left) = bh(x.right) = bh(x)$

$|T(x)| = 1 + |T(x.left)| + |T(x.right)| \geq 1 + 2^{bh(x)-1} + 2^{bh(x)-1} \geq 2^{bh(x)} - 1$

◆ **Fall 2:** $x.color = \text{schwarz}$

$bh(x.left) = bh(x.right) = bh(x) - 1$

$|T(x)| = 1 + |T(x.left)| + |T(x.right)| \geq 1 + 2^{bh(x)-1-1} + 2^{bh(x)-1-1} = 2^{bh(x)} - 1$

■ **Teil 2:**


Es gilt $h(T) \leq 2 bh(\text{root}[T])$ (nach Rot-Schwarz-Eigenschaft 4)

$\Rightarrow N = |T| \geq 2^{bh(\text{root}[T])} - 1 \geq 2^{h(T)/2} - 1 \Leftrightarrow h(T) \leq 2 \log_2(N+1)$

Such-Komplexität in Rot-Schwarz-Bäumen

- Ein Rot-Schwarz-Baum mit n Knoten hat eine maximale Höhe von $O(\log N)$ und ist somit balanciert.
- Sei T ein Suchbaum, der die Rot-Schwarz-Eigenschaft erfüllt.
 - Die Operationen `SEARCH()`, `MINIMUM()`, `MAXIMUM()`, `SUCCESSOR()` und `PREDECESSOR()` laufen in Zeit $O(h) = O(\log N)$
 - Die Operationen `TREE-INSERT()` und `TREE-DELETE()` laufen in Zeit $O(\log N)$
- `TREE-INSERT()` und `TREE-DELETE()` können zu Suchbäumen führen, die die Rot-Schwarz-Eigenschaft verletzen!
 - ➔ Korrektur-Mechanismus zur Wiederherstellung der Rot-Schwarz-Eigenschaft (und somit der Balance) wird benötigt.


Rotationen in Suchbäumen



Rotationen in Suchbäumen

- Definition: Eine **Rotation** ist eine lokale Operation (Umsetzen einer konstanten Anzahl von Zeigern) in Suchbäumen, die die Suchbaum-Eigenschaft erhält.

- `LEFT-ROTATE(T, x)`
1 `y = x.right`
// y's linker Teilbaum → x's rechter Teilbaum
2 `x.right = y.left`
3 **if**(`y.left ≠ T.nil`)
 `y.left.p = x`
// verbinde Vater von x mit y
5 `y.p = x.p`
6 **if**(`x.p == T.nil`)
 `T.root = y`
8 **else if**(`x = x.p.left`)
 `x.p.left = y`
10 **else** `x.p.right = y`
// verschiebe x auf die linke Seite von y
11 `y.left = x`
12 `x.p = y`



Einfügen in Rot-Schwarz-Bäumen

- Durchlaufe den Suchbaum von der Wurzel bis zu einem Blatt, füge den Schlüssel ein, färbe den Knoten rot.

- `RB-INSERT(T, z)`

```
x = T.root
```

```
y = T.nil // speichert p[x]
```

```
while( x ≠ T.nil )
```

```
    y = x
```

```
    if( z.key < x.key ) x = x.left
```

```
    else x = x.right
```

```
z.p = y
```

```
if( y == T.nil ) T.root = z
```

```
else if( z.key < y.key ) y.left = z
```

```
    else y.right = z
```

```
z.left = z.right = T.nil
```

```
z.color = ROT
```

```
// korrigiere die Rot-Schwarz-Eigenschaften
```

```
RB-INSERT-FIXUP(T, z)
```


Korrektur der Rot-Schwarz-Eigenschaft


- Welche Eigenschaften können verletzt sein?
 1. Jeder Knoten ist entweder rot oder schwarz. ✓
 2. Die Wurzel ist schwarz.
 3. Jedes Blatt (der Wächter) ist schwarz. ✓
 4. Für jeden roten Knoten gilt: beide Nachfolger sind schwarz.
 5. Für jeden Knoten x gilt: Alle Pfade von x zu einem Blatt enthalten die gleiche Anzahl $bh(x)$ schwarzer Knoten. ✓
- zu 2.: Ist verletzt, falls z die Wurzel ist
- zu 4.: Ist verletzt, falls $z.p.color = ROT$ ist
- Die Rot-Schwarz-Eigenschaften sind höchstens an einem Knoten (Eigenschaft 2: z oder Eigenschaft 4: $z.p$) verletzt.
- Idee von RB-INSERT-FIXUP:

Korrigiere die Eigenschaftsverletzung 4 lokal oder verschiebe die Eigenschaftsverletzung 4 sukzessiv zum Vorgänger. Wenn die Wurzel erreicht wird, korrigiere Eigenschaft 2.

Die Funktion RB-INSERT-FIXUP()

■ RB-INSERT-FIXUP(T, z)


```
1 while( z.p.color == ROT )
2   if( z.p == z.p.p.left )
3     y = z.p.p.right
4     if( y.color == ROT )
5       z.p.color = SCHWARZ
6       y.color = SCHWARZ
7       z.p.p.color = ROT
8       z = z.p.p
9   else
10    if( z == z.p.right )
11      z = z.p
12      LEFT-ROTATE(T, z)
13      z.p.color = SCHWARZ
14      z.p.p.color = ROT
15      RIGHT-ROTATE(T, z.p.p )
16  else // z.p == z.p.p.right
17    : // wie then-Teil, vertausche right ⇔ left
18
19 T.root.color = SCHWARZ
```



Die Funktion RB-INSERT-FIXUP() – Fall 1

■ RB-INSERT-FIXUP(T, z)

```
1 while( z.p.color == ROT )
2   if( z.p == z.p.p.left )
3     y = z.p.p.right
4     if( y.color == ROT )
5       z.p.color = SCHWARZ
6       y.color = SCHWARZ
7       z.p.p.color = ROT
8       z = z.p.p
9   else
10    if( z == z.p.right )
11      z = z.p
12      LEFT-ROTATE(T, z)
13      z.p.color = SCHWARZ
14      z.p.p.color = ROT
15  else // z.p == z.p.p.right
16    : // wie then-Teil, vertausche right ↔ left
17  T.root.color = SCHWARZ
```



Fall 4-6 (symmetrisch zu 1-3)

Fall 1

Fall 2

Fall 3

Die Funktion RB-INSERT-FIXUP() – Fall 2

■ RB-INSERT-FIXUP(T, z)

```

1 while( z.p.color == ROT )
2   if( z.p == z.p.p.left )
3     y = z.p.p.right
4     if( y.color == ROT )
5       z.p.color = SCHWARZ
6       y.color = SCHWARZ
7       z.p.p.color = ROT
8       z = z.p.p
9   else
10    if( z == z.p.right )
11      z = z.p
12      LEFT-ROTATE(T, z)
13      z.p.color = SCHWARZ
14      z.p.p.color = ROT
15      RIGHT-ROTATE(T, z.p.p )
16  else // z.p == z.p.p.right
17    : // wie then-Teil, vertausche right ↔ left
18
19 T.root.color = SCHWARZ


```

Fall 4-6 (symmetrisch zu 1-3)

Fall 1

Fall 2

Fall 3




Die Funktion RB-INSERT-FIXUP() – Fall 3

■ RB-INSERT-FIXUP(T, z)

```

1 while( z.p.color == ROT )
2   if( z.p == z.p.p.left )
3     y = z.p.p.right
4     if( y.color == ROT )
5       z.p.color = SCHWARZ
6       y.color = SCHWARZ
7       z.p.p.color = ROT
8       z = z.p.p
9   else
10    if( z == z.p.right )
11      z = z.p
12      LEFT-ROTATE(T, z)
13      z.p.color = SCHWARZ
14      z.p.p.color = ROT
15      RIGHT-ROTATE(T, z.p.p )
16  else // z.p == z.p.p.right
17    : // wie then-Teil, vertausche right ↔ left
18
19 T.root.color = SCHWARZ

```



Fall 4-6 (symmetrisch zu 1-3)

Fall 1

Fall 2

Fall 3

Die Funktion RB-INSERT-FIXUP() - Korrektheit

■ Invariante der while-Schleife 1-15:

1. $z.color = ROT$
2. Falls $z.p = T.root$, gilt: $z.p.color = SCHWARZ$
3. Es gibt maximal eine Verletzung der Rot-Schwarz-Eigenschaft:
 1. Eigenschaft 2 $\Rightarrow z = T.root$ und $z.color = ROT$
 2. Eigenschaft 4 $\Rightarrow z.color = ROT$ und $z.p.color = ROT$

■ Gültigkeit der Invariante zum Zeitpunkt der **Initialisierung**:

- zu 1.: Knoten z mit $z.color = ROT$ wurde in einen Rot-Schwarz-Baum ohne Verletzung eingefügt.
- zu 2.: Falls $z.p = T.root$: $z.p.color$ wurde nicht verändert, da T ein Rot-Schwarz-Baum war, gilt $z.p.color = SCHWARZ$.
- zu 3.: Offensichtlich gelten Rot-Schwarz-Eigenschaften 1, 3 und 5 (siehe Folie 25).

Die Funktion RB-INSERT-FIXUP() - Korrektheit

■ Korrektheit von RB-INSERT-FIXUP() zum Zeitpunkt der Terminierung:

- Schleifenbedingung nicht mehr erfüllt: $z.p.color = \text{SCHWARZ}$
- [Falls z die Wurzel ist, ist $z.p = T.nil$ (Wächter) mit $T.nil.color = \text{SCHWARZ}$]


Rot-Schwarz-Eigenschaften (zur Erinnerung)

1. Jeder Knoten ist entweder rot oder schwarz.
2. Die Wurzel ist schwarz.
3. Jedes Blatt (der Wächter) ist schwarz.
4. Für jeden roten Knoten gilt: beide Nachfolger sind schwarz.
5. Für jeden Knoten x gilt: Alle Pfade von x zu einem Blatt enthalten die gleiche Anzahl $bh(x)$ schwarzer Knoten.

- Rot-Schwarz-Eigenschaften 1,3 und 5 sind erfüllt.
- $z.color = \text{ROT}$ und $z.p.color = \text{SCHWARZ} \Rightarrow$
Eigenschaft 4. ist nicht verletzt.
- Eigenschaft 2 kann nach Terminierung der Schleife verletzt sein.
Zeile 16 von RB-INSERT-FIXUP() stellt Eigenschaft 2 her.

Die Funktion RB-INSERT-FIXUP() - Korrektheit


- Die Invariante bleibt bei der **Fortsetzung** der Schleife erhalten:
 - Ist $z.p.p$ definiert? $z.p.color = ROT$, mit Teil 2. der Invariante gilt $z.p \neq T.root$, damit existiert $z.p.p$.
- **Fall 1:** Für Onkel y von z gilt: $y.color = ROT$



- $z.p.p.color = SCHWARZ$, da $y.color = ROT$ und $y.p = z.p.p$ gilt
- Alle Nachfolger $\alpha-\epsilon$ von z , $z.p$ (außer z) und y sind schwarz und haben die gleiche Schwarz-Höhe $bh()$.
- Sei z' der Wert der Variablen z nach Ausführung der Iteration:
 1. *Zeige: $z.color = ROT$*
 $z' = z.p.p$ und $z.p.p.color = ROT$ nach Zeilen 7 und 8.
 2. *Zeige: Falls $z.p = T.root$, gilt: $z.p.color = SCHWARZ$*
 $z'.p = z.p.p.p$ ändert seine Farbe nicht.

Die Funktion RB-INSERT-FIXUP() - Korrektheit

- **Fall 1:** Für Onkel y von z gilt: $y.\text{color} = \text{ROT}$



- Fortsetzung:

3. Zeige: Es gibt maximal eine Verletzung der Rot-Schwarz-Eigenschaft:

1. Eigenschaft 2 $\Rightarrow T.z = \text{root}$ und $z.\text{color} = \text{ROT}$

2. Eigenschaft 4 $\Rightarrow z.\text{color} = \text{ROT}$ und $z.p.\text{color} = \text{ROT}$

Eigenschaft 1., 3. und 5. (siehe Zeichnung) sind nicht verletzt.

Annahme: $z' = T.\text{root}$

- $z'.\text{color} = \text{ROT} \Rightarrow$ Eigenschaft 2 ist verletzt

- $z'.p.\text{color} = \text{SCHWARZ} \Rightarrow$ Eigenschaft 4 ist nicht verletzt


Annahme: $z' \neq T.\text{root}$

- $T.\text{root}.\text{color}$ hat sich nicht geändert \Rightarrow Eigenschaft 2 ist nicht verletzt.

- Eigenschaft 4 an Knotenpaar $(z, z.p)$ erfüllt; falls $z'.p.\text{color} = \text{ROT}$, liegt eine Verletzung von Eigenschaft 4 an Knotenpaar $(z', z'.p)$ vor.

Die Funktion RB-INSERT-FIXUP() - Korrektheit


- **Fall 2:** $y.\text{color} = \text{SCHWARZ}$ und $z = z.p.\text{right}$



- Alle Nachfolger $\alpha-\gamma$ von z , $z.p$ (außer z) und δ sind schwarz und haben die gleiche Schwarz-Höhe $bh()$.
- Überführung in Fall 3 durch Links-Rotation (Zeilen 10-11), Eigenschaft 5 bleibt erhalten.
- **Fall 3:** $y.\text{color} = \text{SCHWARZ}$ und $z = z.p.\text{left}$
 1. *Zeige:* $z.\text{color} = \text{ROT}$
nach Fall 2 gilt $z' = z.p$ und $z.p.\text{color} = \text{ROT}$
in Fall 3 werden weder z noch $z.\text{color}$ verändert.
 2. *Zeige:* Falls $z.p = T.\text{root}$, gilt: $z.p.\text{color} = \text{SCHWARZ}$
nach Fall 3 (Zeile 12) gilt $z.p.\text{color} = \text{SCHWARZ}$.

Die Funktion RB-INSERT-FIXUP() - Korrektheit

- **Fall 3:** $y.\text{color} = \text{SCHWARZ}$ und $z = z.p.\text{left}$



- Fortsetzung:

3. Zeige: Es gibt maximal eine Verletzung der Rot-Schwarz-Eigenschaft:

1. Eigenschaft 2 $\Rightarrow z = T.\text{root}$ und $z.\text{color} = \text{ROT}$

2. Eigenschaft 4 $\Rightarrow z.\text{color} = \text{ROT}$ und $z.p.\text{color} = \text{ROT}$

Eigenschaft 1., 3. und 5. (siehe Zeichnung) sind nicht verletzt.

◆ Eigenschaft 2 ist nicht verletzt, da $z'.p.\text{color} = \text{SCHWARZ}$


◆ Eigenschaft 4 wird für das Knotenpaar $(z, z.p)$ korrigiert. Da $z.p.\text{color} = \text{SCHWARZ}$, gibt es keine weitere Verletzung von Eigenschaft 4.

- **Theorem 8:** RB-INSERT-NODE() fügt einen Knoten unter Erhalt der Rot-Schwarz-Eigenschaften in einen Rot-Schwarz-Baum in Zeit $O(\log N)$ ein.

Löschen aus Rot-Schwarz-Bäumen

```
■ TREE-DELETE-NODE(T, z)                                // Cormen: RB-DELETE()
// y: der (nach Tausch) zu löschende Knoten
1  if( z.left == T.nil or z.right == T.nil )
    y = z
2  else y = TREE-MINIMUM( z.right ) // Cormen: TREE-SUCCESSOR(z)
// x: Kind von y, das nicht NIL ist
3  if( y.left ≠ T.nil ) x = y.left
    else x = y.right
    // entferne y aus der Baumstruktur
4  if( x ≠ NIL ) x.p = y.p                                // if-Abfrage wg. Wächter unnötig
5  if( y.p == NIL ) T.root = x
6  else
    if( y == y.p.left ) y.p.left = x
    else y.p.right = x
    // kopiere Daten von y nach z
8  if( y ≠ z ) z.key = y.key
9  if( y.color == SCHWARZ ) RB-DELETE-FIXUP(T,x)
10 delete y
```

Löschen aus Rot-Schwarz-Bäumen



■ **Korrektheit** von RB-DELETE-NODE() für den Fall $y.\text{color} = \text{ROT}$:

- Die Schwarz-Höhen ändern sich nicht.
- Es entstehen keine benachbarten roten Knoten.
- $y \neq T.\text{root}$, da $T.\text{root}.\text{color} = \text{SCHWARZ}$

Die Funktion RB-DELETE-FIXUP()

- Welche Rot-Schwarz-Eigenschaften können verletzt sein:
 1. *Jeder Knoten ist entweder rot oder schwarz.* ✓
 2. *Die Wurzel ist schwarz.* -
 3. *Jedes Blatt (der Wächter) ist schwarz.* ✓
 4. *Für jeden roten Knoten gilt: beide Nachfolger sind schwarz.* -
 5. *Für jeden Knoten x gilt: Alle Pfade von x zu einem Blatt enthalten die gleiche Anzahl $bh(x)$ schwarzer Knoten.* -
- zu 2.: verletzt, falls $y = T.root$ und $x.color = ROT$
- zu 4.: verletzt, falls $y.p.color = ROT$ und $x.color = ROT$
- zu 5.: verletzt für alle Knoten auf den Pfad von $x.p$ bis zur Wurzel
Alternative Sicht: $x.color = \text{'doppelt-schwarz'}$ oder 'rot-schwarz'
Dann ist 5. erfüllt und dafür 1. (nur an Knoten x) verletzt.


Die Funktion RB-DELETE-FIXUP()

■ RB-DELETE-FIXUP(T, x)

```

1 while( x ≠ T.root and x.color == SCHWARZ )
2   if( x == x.p.left )
3     w = x.p.right // w zeigt auf den Bruder von x
4     if( w.color == ROT )
5       w.color = SCHWARZ
6       x.p.color = ROT
7       LEFT-ROTATE(T, x.p)
8       w = x.p.right
9     if( w.left.color == SCHWARZ and
        w.right.color == SCHWARZ )
10      w.color = ROT
11      x = x.p
12    else if( w.right.color == SCHWARZ )
13      w.left.color = SCHWARZ
14      w.color = ROT
15      RIGHT-ROTATE(T, w)
16      w = x.p.right
17      w.color = x.p.color
18      x.p.color = SCHWARZ
19      w.right.color = SCHWARZ
20      LEFT-ROTATE(T, p[x] )
21      x = T.root
22  else // x == x.p.right // wie then-Teil, vertausche right ⇔ left
23    x.color = SCHWARZ

```



Fall 5-8 (symmetrisch zu 1-4)

Fall 1

F. 2

Fall 3


Fall 4

RB-DELETE-FIXUP() – Korrektur von Eigenschaft 2

■ RB-DELETE-FIXUP(T, x)

```

1 while( x ≠ T.root and x.color == SCHWARZ )
2   if( x == x.p.left )
3     w = x.p.right // w zeigt auf den Bruder von x
4     if( w.color == ROT )
5       w.color = SCHWARZ
6       x.p.color = ROT
7       LEFT-ROTATE(T, x.p)
8       w = x.p.right
9     if( w.left.color == SCHWARZ and
        w.right.color == SCHWARZ )
10      w.color = ROT
11      x = x.p
12    else if( w.right.color == SCHWARZ )
13      w.left.color = SCHWARZ
14      w.color = ROT
15      RIGHT-ROTATE(T, w)
16      w = x.p.right
17      w.color = x.p.color
18      x.p.color = SCHWARZ
19      w.right.color = SCHWARZ
20      LEFT-ROTATE(T, p[x] )
21      x = T.root
22  else // x == x.p.right // wie then-Teil, vertausche right ⇔ left
23    x.color = SCHWARZ
    
```



Fall 5-8 (symmetrisch zu 1-4)

Fall 1

F. 2

Fall 3

Fall 4


RB-DELETE-FIXUP() – Korrektur von Eigenschaft 4

■ RB-DELETE-FIXUP(T, x)

```

1 while( x ≠ T.root and x.color == SCHWARZ )
2   if( x == x.p.left )
3     w = x.p.right // w zeigt auf den Bruder von x
4     if( w.color == ROT )
5       w.color = SCHWARZ
6       x.p.color = ROT
7       LEFT-ROTATE(T, x.p)
8       w = x.p.right
9     if( w.left.color == SCHWARZ and
10        w.right.color == SCHWARZ )
11       w.color = ROT
12       x = x.p
13     else if( w.right.color == SCHWARZ )
14       w.left.color = SCHWARZ
15       w.color = ROT
16       RIGHT-ROTATE(T, w)
17       w = x.p.right
18       w.color = x.p.color
19       x.p.color = SCHWARZ
20       w.right.color = SCHWARZ
21       LEFT-ROTATE(T, p[x] )
22       x = T.root
23   else // x == x.p.right // wie then-Teil vertausche left ↔ right
24     x.color = SCHWARZ

```



Fall 5-8 (symmetrisch zu 1-4)

Fall 1

F. 2

Fall 3

Fall 4

RB-DELETE-FIXUP() – Korrektur von Eigenschaft 1: Fall 1

■ RB-DELETE-FIXUP(T, x)

```

1 while( x ≠ T.root and x.color == SCHWARZ )
2   if( x == x.p.left )
3     w = x.p.right // w zeigt auf den Bruder von x
4     if( w.color == ROT )
5       w.color = SCHWARZ
6       x.p.color = ROT
7       LEFT-ROTATE(T, x.p)
8       w = x.p.right
9       if( w.left.color == SCHWARZ and
10          w.right.color == SCHWARZ )
11         // ...
12         // ...
13         // ...
14         // ...
15         RIGHT-ROTATE(T, w)
16         w = x.p.right
17         w.color = x.p.color
18         x.p.color = SCHWARZ
19         w.right.color = SCHWARZ
20         LEFT-ROTATE(T, p[x] )
21         x = T.root
22     else // x == x.p.right // wie then-Teil, vertausche right ⇔ left
23       x.color = SCHWARZ

```

Fall 1


F. 2

Fall 3


Fall 4

Fall 5-8 (symmetrisch zu 1-4)

Fall 1:
Bedingung: w ist rot
Aktion: vertausche Farben, L-Rotation
Nachbedingung: w ist schwarz (da w schwarze Kinder haben muss)



Überführung in Fall 2-4





RB-DELETE-FIXUP() – Korrektur von Eigenschaft 1: Fall 2

■ RB-DELETE-FIXUP(T, x)

```

1 while( x ≠ T.root and x.color == SCHWARZ )
2   if( x == x.p.left )
3     w = x.p.right // w zeigt auf den Bruder von x
4     if( w.color == ROT )
5       w.color = SCHWARZ
6       x.p.color = ROT
7       LEFT-ROTATE(T, x.p)
8       w = x.p.right
9     if( w.left.color == SCHWARZ and
10        w.right.color == SCHWARZ )
11       w.color = ROT
12       x = x.p
13     else if( w.right.color == SCHWARZ )
14       w.left.color = SCHWARZ
15
16   Fall 2:
17   Bedingung: w hat zwei schwarze Kinder
18   Aktion: w wird rot, verschiebe doppel-schwarz
19   zu p[x]
20   Nachbedingung: x ist (einfach-)schwarz
21
22   LEFT-ROTATE(T, p[x] )
23   x = T.root
24
25   else // x == x.p.right // wie then-Teil, vertausche right ⇔ left
26     x.color = SCHWARZ

```



Fall 5-8 (symmetrisch zu 1-4)

Fall 1

F. 2

Fall 3

Fall 4



RB-DELETE-FIXUP() – Korrektur von Eigenschaft 1: Fall 3

```

1  while( x ≠ T.root and x.color == SCHWARZ )
2    if( x == x.p.left )
3      w = x.p.right // w zeigt auf den Bruder von x
4      if( w.color == ROT )
5        w.color = SCHWARZ


```

Fall 3:
 Bedingung: w ist schwarz, w's rechtes Kind ist schwarz, w's linkes Kind ist rot
 Aktion: Farbentausch und R-Rotation
 Nachbedingung: w's rechtes Kind ist rot


```

10  x = x.p
11  else if( w.right.color == SCHWARZ )
12    w.left.color = SCHWARZ
13    w.color = ROT
14    RIGHT-ROTATE(T, w)
15    w = x.p.right
16    w.color = x.p.color
17    x.p.color = SCHWARZ
18    w.right.color = SCHWARZ
19    LEFT-ROTATE(T, p[x] )
20    x = T.root
21  else // x == x.p.right // wie then-Teil, vertausche right ⇔ left
22  x.color = SCHWARZ

```



Überführung durch Rotation in Fall 4



RB-DELETE-FIXUP() – Korrektur von Eigenschaft 1: Fall 4

```

1  while( x ≠ T.root and x.color == SCHWARZ )
2    if( x == x.p.left )
3      w = x.p.right // w zeigt auf den Bruder von x
4      if( w.color == ROT )
5        w.color = SCHWARZ
6        x.p.color = ROT
7        LEFT-ROTATE(T, x.p)
8        w = x.p.right
9      if( w.left.color == SCHWARZ and
          w.right.color == SCHWARZ )

```

Fall 4:

Bedingung: w ist schwarz, w's rechtes Kind ist rot


Aktion: Farbentausch (nach rechts) und
L-Rotation, x wird (einfach-)schwarz

Nachbedingung: Eigenschaft 1 erfüllt


```

10  RIGHT-ROTATE(T, w)
11  w = x.p.right
12  w.color = x.p.color
13  x.p.color = SCHWARZ
14  w.right.color = SCHWARZ
15  LEFT-ROTATE(T, p[x] )
16  x = T.root
17  else // x == x.p.right // wie then-Teil, vertausche right ⇔ left
18  x.color = SCHWARZ

```



Entfernung
„doppel-“ des
schwarz“



Fall 5-8 (symmetrisch zu 1-4)

Fall 1

F. 2

Fall 3

Fall 4



RB-DELETE-NODE() - Komplexität


- **Theorem 8:** RB-DELETE-NODE() löscht einen Knoten unter Erhalt der Rot-Schwarz-Eigenschaften in einen Rot-Schwarz-Baum in Zeit $O(\log N)$.
 - Die Korrektheit von RB-DELETE-NODE() folgt aus der Diskussion der Fälle.
 - Die Bearbeitung aller Fälle erfolgt in konstanter Zeit.
 - Fall 1 überführt in Fälle 2-4
 - Nach Fall 3 und 4 terminiert die Schleife
 - In Fall 2 wird die Schleife auf dem Elter-Knoten ausgeführt.

- Insgesamt folgt: Ein Rot-Schwarz-Baum realisiert ein Wörterbuch mit asymptotischer Worst-Case Laufzeit $O(\log N)$ für die Operationen INSERT, DELETE und SEARCH.


4.3 AVL-Bäume

[aus Ottmann/Widmeyer, Spektrum Akad. Verlag, 2002]

- AVL-Baum: (Adel'son, Velskiĭ und Landis, 1962)
- Für jeden Knoten p gilt:
 - Sei $p.bal = \text{Höhe}(\text{rechten Teilbaum}) - \text{Höhe}(\text{linker Teilbaum})$
 - Es gilt $p.bal \in \{-1, 0, 1\}$
- Ist ein AVL-Baum balanciert?
 - ein AVL-Baum der Höhe h hat mindestens F_{h+2} Blätter
(F_h : h -te Fibonacci-Zahl; $F_0 = 0$, $F_1 = 1$, $F_{i+2} = F_i + F_{i+1}$)




Höhe 1



Höhe 2, min. Anzahl Blätter

- Es gilt: $F_h \approx 0.72 * 1.62^h$
- $N = 2 * \text{Anzahl der Blätter} - 1 \Rightarrow N_h \geq 2 * F_{h+2} - 1$
- $h = O(\log N)$

Einfügen in AVL-Bäume 1




- Einfügen in AVL-Bäume:
 - Teil 1: Einfügen wie in natürlichen Bäumen (Einfügestelle p)
Balancewerte auf dem Pfad von p zur Wurzel ändern sich
 - Teil 2: Wandere von p zur Wurzel und rebalanciere durch Rotationen



- 

Balancieren nach dem Einfügen: upin-Prozedur


- `upin(p : Zeiger auf AVL_node)`
 - Vorbedingung: $p.bal \in \{-1, 1\}$,
 - Höhe des Teilbaums unter p ist um 1 gewachsen
 - `upin(p)` balanciert die Teilbäume unter $p.parent$ und geht dann rekursiv zum Vater
 - Es gibt 6 verschiedene Fälle (sei $pp = p.parent$) :
 - ◆ $pp.left = p$ (p ist linker Sohn) und $pp.bal = +1, 0$ oder -1 Fall 1.1-1.3
 - ◆ $pp.right = p$ (p ist rechter Sohn) und $pp.bal = +1, 0, -1$ Fall 2.1-2.3
 - Fall 1.1: $pp.left = p$ und $pp.bal = +1$



- $pp.bal \leftarrow 0$
- Höhe von pp bleibt gleich

Balancieren nach dem Einfügen: upin-Prozedur

- Fall 1.2: $pp.\text{left} = p$ und $\text{bal}(pp) = 0$




- $pp.\text{bal} \leftarrow -1$
- Höhe von pp wächst um 1
- \rightarrow führe $\text{upin}(pp)$ aus

- Fall 1.3: $pp.\text{left} = p$ und $pp.\text{bal} = -1$

- $pp.\text{bal} = -2$, Anpassung der Baumstruktur notwendig


- Fall 1.3.1: $p.\text{bal} = -1$



- führe Rechts-Rotation durch
- $pp.\text{bal} \leftarrow 0$, $p.\text{bal} \leftarrow 0$
- Höhe von pp bleibt gleich

Balancieren nach dem Einfügen: upin-Prozedur

■ Fall 1.3.2: $p.bal = +1$



- führe Doppel-Rotation links-rechts aus
- $pp.bal \leftarrow 0$,
- $p.bal \leftarrow 0$ falls $b = -1$; $+1$ falls $b = +1$
- $q.bal \leftarrow -1$ falls $b = -1$; 0 falls $b = +1$
- Höhe von pp bleibt gleich

- Fälle 2.1 – 2.3 sind spiegelsymmetrisch analog
- Löschen in AVL-Bäumen: ähnliche Überlegung, Funktion `upout` zur Höhenbalancierung

Abschließende Kommentare zu Suchbäumen

- Suchbäume eignen sich als **dynamische Datenstruktur für Wörterbücher** mit Operationen INSERT, DELETE und SEARCH.
- Die Laufzeit aller Operationen sind abhängig von der Höhe des Suchbaums. Im Average Case verhält sich die Höhe logarithmisch zur Anzahl gespeicherter Objekte.
- Ein Suchbaum hat im Worst Case die Höhe $\Theta(N)$, im Best Case und Average Case die Höhe $O(\log N)$. Ein Suchbaum mit Höhe $O(\log N)$ heißt **balanciert**.
- **Rot-Schwarz-Bäume** stellen einen Mechanismus zum Balancieren der Suchbäume nach INSERT- und DELETE-Operationen zur Verfügung. Beide Operationen haben im Worst Case Laufzeit $O(\log N)$.
- **AVL-Bäume** verwenden ein alternatives Balance-Kriterium. INSERT- und DELETE-Operationen erzeugen ebenfalls in $O(\log N)$ Zeit balancierte Suchbäume.

4.4 Hashing mit Verkettung

- Bisherige Voraussetzung:

- Schlüssel mit Ordnungsrelation \leq : Suchbäume mit $O(\log N)$ -Laufzeiten für Einfügen, Löschen und Suchen

- Neue Annahme:

- Schlüssel lassen sich auf natürliche Zahlen abbilden.

- Idee (Hashing):


- Berechne aus dem Schlüssel einen Index $h(\text{key})$, speichere die Daten in einem Array an Position $h(\text{key})$. Im RAM-Modell erfolgt der Array-Zugriff in konstanter Zeit.

- Probleme:

- Mehrere Schlüssel werden auf den gleichen Index abgebildet
→ **Kollision**
- Der Index-Raum ist viel größer als die zu speichernden Daten

Direkte Adressierung

- Annahme:
 - Schlüssel sind aus der Menge $U = \{0, \dots, m-1\}$ (*Universalmenge*).
 - Alle Schlüssel sind voneinander verschieden.
 - $m = O(|K|)$, wobei K die Menge der verwendeten Schlüssel ist.
- Idee: Adresstabelle mit direktem Zugriff:



- Operationen INSERT, DELETE, SEARCH sind in $O(1)$ realisierbar.

Hashing

- In der Praxis:
 - $|U| \gg |K|$, d.h. direkte Adressierung ist speicher-ineffizient.
- Ziel: Speicherung mit Platzbedarf $\Theta(|K|)$ unter Erhalt der Laufzeit
- **Hashfunktion:**
 - Funktion zur Abbildung der Universalmenge auf die Menge verfügbarer Speicheradressen: $h: U \rightarrow \{0, \dots, m-1\}$. $h(k)$ ist der **Hashwert** des Schlüssels k . Die Daten werden in einer **Hashtabelle** $T[0, \dots, m-1]$ gespeichert.
- **Kollisionen:**
 - Gilt für zwei Schlüssel $k \neq k' : h(k) = h(k')$, spricht man von einer **Kollision**.
 - Da $|U| > m$ gilt, sind Kollisionen nicht vermeidbar.
- Entwicklungsziele:
 - Handhabung von Kollisionen
 - Minimierung der auftretenden Kollisionen durch Wahl einer geeigneten Hashfunktion


Kollisionsauflösung durch Verkettung

■ Idee:

- Speicherung aller Elemente mit gleichem Hashwert in einer linearen Liste.

■ Operationen:

- INSERT(T, x): füge x an den Kopf der Liste $T[h(x.key)]$ ein $O(1)$
(ohne Test auf Vorhandensein von x)
- DELETE(T, x): entferne x aus der Liste $T[h(x.key)]$ $O(1)$
(dies setzt eine doppelte Verkettung voraus)
- SEARCH(T, k): suche in der Liste $T[h(k)]$ $O(|T[h(x.key)]|)$



Analyse von Hashing mit Verkettung

- **Belegungsfaktor:** $\alpha = n / m$

- $n = |K|$: Anzahl der in der Hashtabelle gespeicherter Objekte
- $m = |T|$: Die Größe der Hashtabelle
- beschreibt die mittlere Anzahl Objekte pro Eintrag in der Hashtabelle

- Annahme: **einfaches, gleichmäßiges Hashing**

Sei X_{ij} das Ereignis, dass Objekt i den Hashwert j erhält. Dann sei $\Pr\{X_{ij}=1\} = 1/m$ und X_{ij} und X_{ik} sind stochastisch unabhängig.

- **Lemma:** Sei $n_j = T[j].\text{length}$, dann gilt $E[n_j] = \alpha = n / m$

- **Theorem 9:** In einer Hashtabelle mit Verkettung unter Annahme des einfachen, gleichmäßigen Hashings benötigt die *erfolglose* Suche $O(1 + \alpha)$ erwartete Laufzeit.

- Ein nicht enthaltener Schlüssel k wird im Wahrscheinlichkeit $1/m$ in Liste $h(k)$ abgelegt. Es gilt $E[n_{h(k)}] = \alpha$.
- Bei erfolgloser Suche wird die Liste $T[h(k)]$ in erwarteter Zeit $O(\alpha)$ vollständig durchlaufen, die Berechnung von $h(k)$ erfolgt in $O(1)$.

Analyse von Hashing mit Verkettung

■ **Theorem 10:** In einer Hashtabelle mit Verkettung unter Annahme des einfachen, gleichmäßigen Hashings benötigt die *erfolgreiche* Suche $O(1 + \alpha)$ erwartete Laufzeit.

- Sei $X = x_1, \dots, x_n$ die Folge, in der die Objekte mit Schlüsseln k_1, \dots, k_n in die Hashtabelle eingefügt wurden. Sei X_{ij} das Kollisions-Ereignis $h(k_i) = h(k_j)$.
- $\text{SEARCH}(T, x_i)$ durchläuft alle Objekte x_j , die nach x_i eingefügt wurden und in der gleichen Liste stehen, also mit $X_{ij}=1$. Dann folgt:

$$E[T_{\text{search}}(n)] = E\left[\frac{c}{n} \sum_{i=1}^n \left(1 + \sum_{j=i+1}^n X_{ij}\right)\right]$$

Mittelung über alle mgl. Suchanfragen x_i

$$= \frac{c}{n} \sum_{i=1}^n \left(1 + \sum_{j=i+1}^n E[X_{ij}]\right)$$

wg. Linearität des Erwartungswertes

$$= \frac{c}{n} \sum_{i=1}^n \left(1 + \sum_{j=i+1}^n \frac{1}{m}\right)$$

wg. einfachem gleichmäßigen Hashing

$$= c + \frac{c}{nm} \sum_{i=1}^n \left(\sum_{j=i+1}^n 1\right)$$

wg. Gauß'scher Summenformel

$$= c + \frac{c}{nm} \sum_{i=1}^n (n-i) = c + \frac{c}{nm} \left(n^2 - \frac{n(n+1)}{2}\right) = c \left(1 + \frac{n-1}{2m}\right) = c \left(1 + \frac{\alpha}{2} - \frac{\alpha}{2n}\right) = O(1 + \alpha)$$

Hashfunktionen

- Anforderungen an Hashfunktionen:
 - leicht und schnell berechenbar
 - gleichmäßige Verteilung der Schlüsselmenge auf die Plätze $0, \dots, m-1$
 - Achtung: Häufung hängt von der Anwendung ab, d.h.
 - ◆ Vermeidung anwendungsverursachter Häufungen
- Überprüfung der Qualität von Hashfunktionen:
 - Es gibt viele mögliche Hashfunktionen, zur sinnvollen Auswahl muss man etwas über die Verteilung von K wissen.
- Heuristische Wahl:
 - Hashwerte sollten keine Häufungen für erwartete Muster zeigen.
- Annahme: Im folgenden gelte:

Schlüsselwerte k sind nicht-negative, ganze Zahlen, also $k \in \mathbb{N}_0$

 - die meisten Schlüssel lassen sich sinnvoll in Zahlen aus \mathbb{N}_0 konvertieren
 - ◆ Universalität des binären Codes

Achtung: Auch bei dieser Konvertierung kann bereits Häufung eine Rolle spielen.

Hashfunktionen: Divisions- und Multiplikationsmethode

■ Divisionsmethode $h: U \rightarrow \{0, \dots, m-1\} : h(k) = k \bmod m$


- ◆ m gerade: k gerade $\Rightarrow h(k)$ ist gerade
- ◆ $m = 2^p$: nur die p -letzten Bits werden zur Generierung von $h(k)$ herangezogen
- ◆ Im allgemeinen sollte m möglichst wenig Teiler haben (Primzahl!)

ABER: Wenn die Schlüsselmenge K in U gleichverteilt ist, dann ergibt auch $m = 2^p$ keine Häufung. Operation $\bmod 2^p$ ist wesentlich effizienter als $\bmod m'$ mit einer Primzahl m' !

■ Multiplikationsmethode $h: U \rightarrow \{0, \dots, m-1\} : h(k) = \lfloor m(kA \bmod 1) \rfloor$

- Definition: Es sei $x \bmod 1 = x - \lfloor x \rfloor$ der ganzzahlige Rest von x

- ◆ m kann unabhängig von A gewählt werden, z.B. $m = 2^p$
- ◆ mit $A = s/2^w$ (w = Wortlänge des Computers) kann die Binärarithmetik des Prozessors optimal ausgenutzt werden
- ◆ $A \approx (\sqrt{5} - 1)/2$ (D. Knuth)



Universelles Hashing

- Für jede Hashfunktion gibt es eine Menge von n Schlüsseln, die auf den gleichen Platz abgebildet werden (vorausgesetzt $U > nm$).
- Wie können wir im Mittel eine gute Performanz erhalten?
- **Universelles Hashing:** Zufällige Auswahl einer Hashfunktion unabhängig von der Schlüsselmenge
- Definition: Eine Menge $H = \{ h: U \rightarrow \{0, \dots, m-1\} \}$ von Hashfunktionen heißt **universell**, g.d.w. $\forall k, l \in U : |\{ h \in H \mid h(k) = h(l) \}| \leq |H|/m$
- Bei zufälliger Wahl einer Hashfunktion und zweier Zahlen $k, l \in U$ ist die Wahrscheinlichkeit der Kollision $[h(k) = h(l)] \leq 1/m$.

Universelles Hashing

- **Theorem 11:** Sei $h \in H$ aus einer Menge universeller Hashfunktionen mit $h: U \rightarrow \{0, \dots, m-1\}$. Nach Speicherung von n Schlüsseln in Tabelle T (Hashing mit Verkettung) gilt für einen Schlüssel k die erwartete Listenlänge:
$$E[n_{h(k)}] \leq \begin{cases} \alpha & : k \notin T \\ 1 + \alpha & : \text{sonst} \end{cases}$$

- **Beweis:**

- Für ein Paar $k, l \in U$ sei X_{kl} das Kollisionseignis $h(k) = h(l)$.
- Da H universell ist, folgt $\Pr\{h(k) = h(l)\} \leq 1/m$ und somit

$$E[X_{kl}] = \sum_{z=0}^1 z \Pr\{X_{kl} = z\} \leq 1/m$$

- **Fall 1:** $k \notin T$

$$E[n_{h(k)}] = E\left[\sum_{l \in T} X_{kl}\right] = \sum_{l \in T} E[X_{kl}] \leq \sum_{l \in T} \frac{1}{m} = \frac{n}{m} = \alpha$$

- **Fall 2:** $k \in T$

$$E[n_{h(k)}] = E\left[\sum_{l \in T} X_{kl}\right] = 1 + \sum_{l \in T \setminus \{k\}} E[X_{kl}] \leq 1 + \sum_{l \in T \setminus \{k\}} \frac{1}{m} = 1 + \frac{n-1}{m} < 1 + \alpha$$

Universelles Hashing

- **Korollar:** Bei universellem Hashing mit Verkettung mit m Plätzen ist die erwartete Laufzeit von p INSERT-, SEARCH- und DELETE-Operationen mit $O(m)$ INSERT-Operationen $O(p)$.

- **Beweis:**

- Nach $O(m)$ INSERT-Operationen gilt $\alpha \leq \frac{cm}{m} = O(1)$
- $T_{\text{INSERT}} = O(1)$, $T_{\text{DELETE}} = O(1)$
- SEARCH-Operation mit Schlüssel k :
 - ◆ Für die erwartete Listenlänge gilt $E[n_{h(k)}] \leq \alpha$, bzw. $E[n_{h(k)}] \leq 1 + \alpha$
 - ◆ Somit folgt $E[T_{\text{SEARCH}}] = O(1 + \alpha) = O(1)$
- Für p Operationen ergibt sich somit eine erwartete Laufzeit von $O(p)$

- **Klasse von universellen Hashfunktionen (ohne Beweis):**

Sei p eine Primzahl mit $p > m$ und $p > k \ \forall \ k \in U$, sei $Z_x = \{0, \dots, x-1\}$. Dann ist $H_{p,m}$ mit

$$h_{a,b} : U \rightarrow Z_m : h_{a,b}(k) = ((ak + b) \bmod p) \bmod m$$

$$H_{p,m} = \{h_{a,b} : a \in Z_p \setminus \{0\} \text{ und } b \in Z_p\}$$

eine Klasse universeller Hashfunktionen mit $|H_{p,m}| = p(p-1)$

4.5 Offene Adressierung

- Nachteile von Hashing mit Verkettung:
 - zusätzlicher Speicherbedarf für Zeiger
 - komplexe Speicherverwaltung (Belegen und Befreien von Listenelementen)
 - ineffiziente Speichernutzung bei Häufung

- Offene Adressierung
 - einmaliges Anlegen von Speicher für die Hashtabelle
 - für Überläufer wird ein anderer Platz **in** der Hashtabelle gesucht (eine *offene* Stelle)
 - dieser andere Platz wird berechnet, so dass Zeiger zur Verkettung nicht notwendig sind.
 - **Sondieren**: Sukzessives Überprüfen der Hashtabelle nach freien Plätzen
 - **Sondierungssequenz**: Folge von Hashadressen, die für einen Schlüssel k nach offenen Stellen durchsucht werden
 - ◆ Hashfunktion $h: U \times \{0, \dots, m-1\} \rightarrow \{0, \dots, m-1\}$
 - ◆ **Sondierungszahl** (2. Parameter): gibt den Sondierungsversuch an

Offene Adressierung: Einfügen

- Eigenschaften von Sondierungsfolgen

- $\forall k \in U : h(k,j)$ ist eine bijektive Funktion

Im Laufe der Sondierung werden alle Speicherplätze getestet.

- Sondierungssequenz hängt vom Schlüssel k ab.

- Eigenschaften der Hashtabelle

- $T[0, \dots, m-1], T[i] \in \{\text{NIL}, \text{DELETED}\} \cup U$

- keine Satellitendaten (diese können jedoch einfach integriert werden)

- Initialisierung: $T[i] = \text{NIL} \ \forall i \in \{0, \dots, m-1\}$

- `HASH-INSERT-PRE(T, k)`

`i = 0`

repeat

`j = h(k, i)`

if(`T[j] == NIL`) `T[j] = k`; **return** j

else `i = i+1`

until(`i == m`)

error „Hashtable overflow!“

Offene Adressierung: Suchen

- Suchalgorithmus:

- Folge der Sondierungssequenz für k und vergleiche den Schlüssel

- `HASH-SEARCH(T, k)`

```
i = 0
```

```
repeat
```

```
    j = h(k, i)
```

```
    if( T[j] == k ) return j
```

```
    else i = i+1
```

```
until( T[j] == NIL or i == m )
```

```
return NIL
```

- Was passiert, wenn ein Schlüssel k gelöscht wird?

- Schlüssel, die nach k gespeichert werden, können nicht wiedergefunden werden, da die Repeat-Schleife bei $T[j]=\text{NIL}$ terminiert!

Offene Adressierung: Einfügen und Löschen

■ Löschverfahren:

- Suche den Platz $T[i]$ mit $T[i] = k$ und setze $T[i] = \text{DELETED}$
- Suchen: behandle DELETED wie einen belegten Platz
- Einfügen: behandle DELETED wie einen freien Platz

■ $\text{HASH-INSERT}(T, k)$

```
i = 0
repeat
    j = h(k, i)
    if( T[j] ∈ {NIL, DELETED} )
        T[j] = k; return j
    else i = i+1
until( i == m )
error „Hashtable overflow!“
```

■ $\text{HASH-DELETE}(T, k)$

```
i = 0
repeat
    j = h(k, i)
    if( T[j] == k )
        T[j] = DELETED; return j
    else i = i+1
until( T[j] == NIL or i == m )
return NIL
```

- ACHTUNG: Laufzeit von $\text{HASH-SEARCH}()$ hängt nicht mehr vom Belegungsfaktor α ab, sondern von $|\{i \in \{0, \dots, m-1\} \mid T[i] \neq \text{NIL}\}|$
=> In Anwendungen mit vielen DELETE -Operationen sollte Hashing mit Verkettung zur Kollisionsauflösung verwendet werden.

Offene Adressierung: Ein Beispiel

■ Beispiel:

- Markierungen: N: NIL
D: DELETED
U: USED, d.h. ein Schlüssel ist dort gespeichert
- Hashfunktion: $h(k,i) = (k + i) \bmod 7$

leere Hashtabelle


0	1	2	3	4	5	6
N	N	N	N	N	N	N

insert(15):

0	1	2	3	4	5	6
	15					
N	U	N	N	N	N	N


insert(36):

0	1	2	3	4	5	6
	15	36				
N	U	U	N	N	N	N



search(71): $\rightarrow -1$

0	1	2	3	4	5	6
	15	36				
N	U	U	N	N	N	N




Offene Adressierung: Ein Beispiel

insert(17):

0	1	2	3	4	5	6
	15	36	17			
N	U	U	U	N	N	N


search(36): → 2

0	1	2	3	4	5	6
	15	36	17	29		
N	U	U	U	U	N	N




search(29): → 4

0	1	2	3	4	5	6
	15	36	17	29		
N	U	D	U	U	N	N




insert(29):

0	1	2	3	4	5	6
	15	36	17	29		
N	U	U	U	U	N	N




delete(36):

0	1	2	3	4	5	6
	15	36	17	29		
N	U	D	U	U	N	N



insert(71):

0	1	2	3	4	5	6
	15	71	17	29		
N	U	U	U	U	N	N



Offene Adressierung: Sondierungsfunktionen

- Hilfshashfunktion $h': U \rightarrow \{0, \dots, m-1\}$
- Sondierungsfunktionen:
 - **Lineares Sondieren** (linear probing): $h(k, i) = (h'(k) + i) \bmod m$
 - ◆ Von $h'(k)$ aus wird jeweils der nächst größere Platz getestet.
 - ◆ Problem: Es entstehen lange Ketten besetzter Plätze:
 $\Pr\{\text{Kette der Länge } i \rightarrow \text{Kette der Länge } i+1\} = (i+1)/m$
 - ◆ Bei insert ist die Wahrscheinlichkeit groß, lange Ketten zu verlängern
→ „**primäres Clustern**“
 - **Quadratisches Sondieren** (quadratic probing):
 - ◆ $h(k, i) = (h'(k) + c_1 i + c_2 i^2) \bmod m$ mit $c_2 \neq 0$
 - ◆ m , c_1 und c_2 müssen so gewählt werden, dass $h(k, i)$ bzgl. i bijektiv ist.
 - ◆ Problem: Bei Kollisionen $h'(k) = h'(k')$ haben beide Schlüssel die gleiche Sondierungsfolge → „**sekundäres Clustern**“

Offene Adressierung: Doppeltes Hashing

- Hilfshashfunktionen $h_1: U \rightarrow \{0, \dots, m-1\}$, $h_2: U \rightarrow \{1, \dots, m'\}$ mit $m' < m$
 - Verwende h_1 , um den Startpunkt der Sondierungsfolge zu bestimmen
 - Verwende h_2 , um den Offset der Sondierungsfolge zu bestimmen
- **Doppeltes Hashing** (double hashing):
 - $h(k, i) = (h_1(k) + i h_2(k)) \bmod m$
 - ◆ $h(k, i)$ ist bzgl. i nur bijektiv, falls $h_2(k) \neq 0$ und $h_2(k)$ teilerfremd zu m ist
 - ◆ Ideal: h_1 und h_2 sind bzgl. der Kollisionswahrscheinlichkeit stochastisch **unabhängig**:
$$P(h_1(k)=h_1(k') \text{ und } h_2(k)=h_2(k')) = P(h_1(k)=h_1(k')) * P(h_2(k)=h_2(k'))$$
 - ◆ Es werden $\Theta(m^2)$ verschiedene Sondierungssequenzen verwendet.
- Beispiele:
 1. m ist eine Primzahl, $h_1(k) = k \bmod m$; $h_2(k) = 1 + k \bmod (m-2)$
 2. $m = 2^l$; $h_1(k) = k \bmod m$; $h_2(k) = 1 + 2k \bmod (m/2)$

Offene Adressierung: Analyse

- Annahmen:
 - Komplexität in Abhängigkeit vom Belegungsfaktor α , $\alpha < 1$
 - Gleichmäßiges Hashing: Alle Sondierungssequenzen $h(k,i)$, $0 \leq i < m$ sind gleich wahrscheinlich (Achtung: durch keine Sondierungsfunktion erfüllt!)
- Wie viele Sondierungsschritte sind im Falle einer erfolglosen / erfolgreichen Suche zu erwarten?
- **Theorem 12:** Für eine Hashtabelle mit offener Adressierung und Belegungsfaktor $\alpha < 1$ ist die erwartete Anzahl der Sondierungen bei *erfolgloser Suche* unter der Annahme des gleichmäßigen Hashings höchstens $1 / (1 - \alpha)$.
- Beweis:
 - Jede Sondierung außer die letzte greift auf einen belegten Platz zu.
 - X : Anzahl der durchgeführten Sondierungen
 - A_i : Ereignis, dass es eine i -te Sondierung gibt, die auf einen belegten Platz zugreift.

Offene Adressierung: Analyse

■ Beweis Theorem 12 (Fortsetzung)

1. Hilfsgleichung:

$$\begin{aligned} E[X] &= \sum_{i=1}^m i \Pr\{X = i\} = \sum_{i=1}^m i (\Pr\{X \geq i\} - \Pr\{X \geq i+1\}) \\ &= \sum_{i=1}^m i \Pr\{X \geq i\} - \sum_{i=1}^m i \Pr\{X \geq i+1\} \\ &= \sum_{i=1}^m i \Pr\{X \geq i\} - \sum_{i=2}^{m+1} (i-1) \Pr\{X \geq i\} \\ &= \sum_{i=1}^m i \Pr\{X \geq i\} - \sum_{i=1}^m (i-1) \Pr\{X \geq i\} \\ &= \sum_{i=1}^m \Pr\{X \geq i\} \end{aligned}$$

siehe Cormen C.24

2. Hilfsgleichung:

$$\sum_{i=0}^{\infty} x^i = \frac{1}{1-x} \quad \text{für } |x| < 1$$

unendlich fallende geometrische Reihe, siehe Cormen A.6

Offene Adressierung: Analyse

■ Beweis Theorem 12 (Fortsetzung)

$$\begin{aligned}\Pr\{X \geq i\} &= \Pr\left\{\bigcap_{k=1}^{i-1} A_k\right\} \\ &= \Pr\{A_1\} \cdot \Pr\{A_2 \mid A_1\} \cdot \Pr\{A_3 \mid A_1 \cap A_2\} \cdots \Pr\left\{A_{i-1} \mid \bigcap_{k=1}^{i-2} A_k\right\} \\ &= \frac{n}{m} \cdot \frac{n-1}{m-1} \cdot \frac{n-2}{m-2} \cdots \frac{n-i+2}{m-i+2} \leq \left(\frac{n}{m}\right)^{i-1} = \alpha^{i-1}\end{aligned}$$

$$\begin{aligned}E[X] &= \sum_{i=1}^m i \Pr\{X = i\} = \sum_{i=1}^m \Pr\{X \geq i\} \\ &\leq \sum_{i=1}^{\infty} \alpha^{i-1} = \sum_{i=0}^{\infty} \alpha^i = \frac{1}{1-\alpha}\end{aligned}$$

Offene Adressierung: Analyse

■ Interpretation:

- $E[X] \leq 1 + \alpha + \alpha^2 + \alpha^3 + \dots$
- Eine Sondierung findet immer statt.
- Die Wahrscheinlichkeit für eine zweite Sondierung ist α
- Die Wahrscheinlichkeit für eine dritte Sondierung ist $\alpha^2 \dots$

■ Beispiele (erfolglose Suche):

- $\alpha = 0,5$, d.h. die Hashtable ist halb voll: $E[X] \leq 1/(1-0,5) = 2$
- $\alpha = 0,9$, d.h. die Hashtable ist 90% voll: $E[X] \leq 1/(1-0,9) = 10$
- $\alpha = 0,99$, d.h. die Hashtable ist 99% voll: $E[X] \leq 1/(1-0,99) = 100$

- **Korollar:** Unter der Annahme des gleichmäßigen Hashings benötigt HASH-INSERT() im Mittel höchstens $1/(1-\alpha)$ Sondierungen.
- HASH-INSERT() benötigt konstante Zeit pro Sondierung + konstante Zeit für das Einfügen des Elements, also asymptotisch im Mittel $O(1/(1-\alpha))$.

Offene Adressierung: Analyse

- **Theorem 13:** Für eine Hashtabelle mit offener Adressierung und Belegungsfaktor $\alpha < 1$ ist die Anzahl der Sondierungen bei *erfolgreicher Suche* unter den Annahmen (1) gleichmäßiges Hashing und (2) gleiche Wahrscheinlichkeit für den Suchschlüssel höchstens $(1/\alpha) \ln(1/(1-\alpha))$.

- **Beweis:**

- Angenommen, der gesuchte Schlüssel k war der $(i+1)$ -te Schlüssel bzgl. der Einfüge-Reihenfolge. Dann war zum Zeitpunkt der Einfügung

$\alpha = i/m$ und nach Theorem 12 gilt: $E[X(\text{HASH-SEARCH}(T, k))] \leq \frac{1}{1-i/m}$

- Mittelung über alle möglichen Suchschlüssel ergibt:


$$\begin{aligned} E[X] &= \frac{1}{n} \sum_{i=0}^{n-1} \frac{1}{1-i/m} = \frac{1}{n} \sum_{i=0}^{n-1} \frac{m}{m-i} = \frac{m}{n} \left(\sum_{i=0}^{n-1} \frac{1}{m-i} \right) \\ &= \frac{1}{\alpha} \left(\frac{1}{m} + \frac{1}{m-1} + \dots + \frac{1}{m-n+1} \right) = \frac{1}{\alpha} \left(\sum_{i=m-n+1}^m \frac{1}{i} \right) \\ &= \frac{1}{\alpha} \left(\sum_{i=1}^m \frac{1}{i} - \sum_{i=1}^{m-n} \frac{1}{i} \right) = \frac{1}{\alpha} (H_m - H_{m-n}) \end{aligned}$$

H_m : m-te harmonische Zahl
siehe Cormen A.7

Offene Adressierung: Analyse

■ Beweis Theorem 13 (Fortsetzung)

$$\begin{aligned} E[X] &= \frac{1}{n} \sum_{i=0}^{n-1} \frac{1}{1-i/m} = \frac{1}{n} \sum_{i=0}^{n-1} \frac{m}{m-i} = \frac{m}{n} \left(\sum_{i=0}^{n-1} \frac{1}{m-i} \right) \\ &= \frac{1}{\alpha} \left(\frac{1}{m} + \frac{1}{m-1} + \dots + \frac{1}{m-n+1} \right) = \frac{1}{\alpha} \left(\sum_{i=m-n+1}^m \frac{1}{i} \right) \\ &\leq \frac{1}{\alpha} \int_{m-n}^m \frac{1}{x} dx \\ &= \frac{1}{\alpha} (\ln(m) - \ln(m-n)) \\ &= \frac{1}{\alpha} \ln \left(\frac{m}{m-n} \right) = \frac{1}{\alpha} \ln \left(\frac{1}{1-\alpha} \right) \end{aligned}$$



Approximation von Summe durch Integral, siehe Cormen A.2

■ Beispiele:

- $\alpha = 0,5$, d.h. die Hashtable ist halbvoll: $E[X] \leq 2 \ln(2) \approx 1,39$
- $\alpha = 0,9$, d.h. die Hashtable ist 90% voll: $E[X] \leq 10/9 \ln(10) \approx 2,56$
- $\alpha = 0,99$, d.h. die Hashtable ist 99% voll: $E[X] \leq 100/99 \ln(100) \approx 4,65$

Einfügen mit Vertauschen: Brents INSERT-Operation

[siehe Ottmann, Widmayer, Spektrum Akad. Verlag 2002, Kap. 4.3]

- Doppeldes Hashing mit Brents INSERT-Algorithmus:

- Betrachte zwei alternative Plätze für k (j_{next}) und $T[k]$ (j_{alt})

- BRENT-INSERT(T, k)

```
t = 0; j = h1(k)
```

```
while( T[j] ∉ {NIL, DELETED} and t < m )
```

```
    t = t+1
```

```
    jnext = (j + h2(k)) mod m
```

```
    jalt = (j + h2(T[j])) mod m
```

```
    if( T[jnext] ∈ {NIL, DELETED}
```

```
        or T[jalt] ∉ {NIL, DELETED} ) j = jnext
```

```
    else SWAP( k, T[j] ); j = jalt
```

```
    if( t == m ) error „Hashtable overflow!“
```

```
    else T[j] = k
```


Der Algorithmus ist korrekt, allerdings ist es nicht Brents INSERT-Operation.

Einfügen mit Vertauschen: Brents INSERT-Operation

[siehe Knuth, Art of Computer Programming, Vol 3, Kap. 6.4]

■ Doppeldes Hashing mit Brents INSERT-Algorithmus:

- Betrachte für eine Sondierungsfolge p_0, p_1, \dots, p_t nach jedem erfolglosem Sondierungsschritt i die Möglichkeit, die Schlüssel $T[p_0], \dots, T[p_{i-1}]$ durch $(t-i-1)$ -faches Sondieren zu platzieren.
- Worst-Case Laufzeit für BRENT-INSERT() ist quadratisch in der Anzahl der Sondierungen
- durchschn. Suchzeit < 2.5 (ohne Löschen) ist unabhängig von α !



Falls $T[q_{r+(t-i-1)}] \in \{\text{NIL}, \text{DELETED}\}$:

$T[q_{r+(t-i-1)}] \leftarrow x$ Sondierungsfolge q für x verlängert sich um $t - i - 1$

$T[p_i] \leftarrow k$ Sondierungsfolge p für k verkürzt sich um $t - i$

Bilanz: Sondierungsfolgen sind um 1 kürzer als bei doppeltem Hashing

Einfügen mit Vertauschen: Brents INSERT-Operation

```
■ BRENT-INSERT(T, k)
  t = 0          // zählt die Anzahl der Sondierungsschritte
  j = h1(k)      // aktuell sondierte Position für Schlüssel k
  while( T[j] ∉ {NIL, DELETED} and t < m )
    t = t+1
    j = (j + h2(k)) mod m
    if( t ≥ 2 and T[j] ∉ {NIL, DELETED} )      // Brents Modifikation
      p_i = h1(k)
      for i = 0 to t-2 do
        // teste, ob T[p_i] mit einem weiteren Sondierungsschritt eingefügt
        // werden kann
        x = T[p_i]
        q_next = ( p_i + (t-i-1)h2(x) ) mod m
        if( T[q_next] ∈ {NIL, DELETED} )
          T[q_next] = x
          T[p_i] = DELETED; j = p_i
          break;
      p_i ← ( p_i + h2(k) ) mod m
  if( t == m ) error „Hashtable overflow!“
  else T[j] = k; return j
```

Abschließende Kommentare zu Hashing

- Durch Umrechnung von Schlüssel in Indizes (**Hashfunktion**) lässt sich ein Wörterbuch-Datenstruktur mit nahezu konstanten durchschnittlichen Laufzeiten für INSERT, DELETE und SEARCH realisieren.
- Laufzeiten im Average Case hängen vom **Belegungsfaktor** ab.
- **Kollisionen sind nicht vermeidbar**, im Worst-Case haben die Wörterbuch-Operationen Laufzeit $\Theta(N)$.
- Werden häufig Daten gelöscht, sollten **Kollisionen durch Verkettung** aufgelöst werden.
- **Offene Adressierung** ist speichereffizienter als Verkettung, allerdings wirkt die Operation DELETE laufzeitschädlich auf SEARCH. Offene Adressierung sollte nur angewandt werden, wenn wenige DELETE-Operationen notwendig sind.
- Bei der offenen Adressierung ist **Doppeltes Hashing** die zu bevorzugende Sondierungsmethode.
- **Brents INSERT-Operation** mit Doppeltem Hashing ermöglicht das Suchen mit durchschnittlich weniger als 2.5 Sondierungsschritten.
- Für statische Datenmengen gibt es **perfekte Hashverfahren** mit Worst-Case Laufzeit $O(1)$ für INSERT und SEARCH (nicht Teil dieser Vorlesung).